Zachodniopomorski
Uniwersytet Technologiczny
w Szczecinie

Wydział Informatyki
kierunek studiów: Informatyka
specjalność: Inżynieria Oprogramowania

Praca dyplomowa inżynierska

STEROWANIE KURSOREM MYSZY ZA POMOCĄ POTENCJAŁÓW WYWOŁYWANYCH STANU USTALONEGO

CONTROLLING THE MOUSE CURSOR USING SSVEP EVOKED POTENTIALS

Michał Pytkowski

nr albumu: **53961**

Opiekun:

dr hab. Izabela Rejer

Katedra Inżynierii Systemów Informacyjnych

Szczecin, 2026

Streszczenie

Celem pracy jest opracowanie i implementacja aplikacji umożliwiającej bezdotykowa sterowanie kursorem myszy za pomocą sygnałów SSVEP (Steady-State Visual Evoked Potentials). Aplikacja pozwoli na kontrolę ruchu kursora w czterech kierunkach (góra, dół, lewo, prawo) oraz symulowanie kliknięcia lewym przyciskiem myszy. Użytkownik będzie sterował kursorem poprzez skupienie wzroku na wyświetlanych na ekranie polach migających z ustalonymi częstotliwościami. Aplikacja będzie składała się z trzech głównych modułów, obejmujących: moduł do odczytu i przetworzenia sygnału EEG; stymulator ekranowy; oraz moduł sterujący pracą myszki. Praca zostanie wykonana w środowisku Python z wykorzystaniem specjalizowanej biblioteki do odczytu przetwarzania sygnału EEG (mne).

słowa kluczowe: SSVEP, EEG, interfejs mózg-komputer (BCI), Python

Abstract

The aim of this work is to develop and implement an application enabling touchless mouse cursor control using SSVEP (Steady-State Visual Evoked Potentials) signals. The application will allow for cursor movement control in four directions (up, down, left, right) and simulate left-clicks. The user will control the cursor by focusing their gaze on on-screen fields that flash at predetermined frequencies. The application will consist of three main modules: an EEG signal acquisition and processing module; an on-screen stimulator; and a mouse control module. The work will be implemented in Python using a specialized EEG signal acquisition and processing library (mne).

keywords: SSVEP, EEG, mouse cursor control, brain-computer interface (BCI), Python

Spis treści

Wstęp 7

1 Interfejs mózg-komputer 9

1.1 Komunikacja z komputerem w dzisiejszych czasach 10

1.2 Zastosowania interfejsów mózg-komputer 11

1.3 Struktura interfejsu mózg-komputer 12

1.4 Metody badania aktywności mózgu 13

1.5 Pomiar sygnału EEG 14

1.6 Rytmy EEG 15

2 Interfejs korzystający z wzrokowych potencjałów wywołanych stanu ustalonego 19

2.1 Wzrokowe potencjały wywołane stanu ustalonego (SSVEP) 19

2.2 Struktura interfejsu SSVEP 19

2.3 Sposoby prezentacji bodźców 20

2.4 Akwizycja sygnałów EEG w interfejsach SSVEP 22

2.5 Metody przetwarzania wykorzystane w interfejsie SSVEP 22

2.6 Przykładowe interfejsy SSVEP 25

3 Projekt oraz implementacja interfejsu SSVEP 27

3.1 Założenia projektowe 27

3.2 Model systemu 28

3.3 Zestaw technologii i proces rejestracji sygnału 28

3.4 Implementacja przetwarzania i klasyfikacji sygnału 29

3.5 Interfejs użytkownika i wygląd stymulatora 31

Podsumowanie 33

Spis literatury 35
Książki 35
Artykuły 35
Źródła internetowe i inne 38

A Dodatek 41

Wstęp

Wstęp powinien być nie dłuższy niż 2 strony. Najlepiej napisać go dopiero, gdy praca jest już skończona i wszystkie jej części spisane.

Wstęp powinien zawierać:

1. Opis dziedziny jakiej dotyczy praca, ze wskazaniem, że temat pracy jest ważny, bieżący, itp.
2. Jaki problem z dziedziny się rozwiązuje.
3. Cel i teza pracy
4. W jaki sposób cel zostanie osiągnięty a tez potwierdzona.
5. Struktura pracy.

1. Interfejs mózg-komputer

Od najdawniejszych czasów człowiek starał się poszerzać swoje możliwości poznawcze i praktyczne za pomocą narzędzi. Pierwsze z nich - jak liczydła czy kamienne tablice - służyły do wspomagania podstawowych operacji arytmetycznych. Z biegiem stuleci te proste urządzenia przekształciły się w coraz bardziej złożone maszyny obliczeniowe, aż po koncepcje maszyn programowalnych. U podstaw tego rozwoju leżała nie tylko potrzeba zwiększenia mocy obliczeniowej, lecz także dążenie do uproszczenia komunikacji między człowiekiem a narzędziem.

Za prekursora tej idei uważa się Charlesa Babbage'a, który w XIX wieku zaprojektował maszynę analityczną - pierwszą koncepcję programowalnego komputera [1]. W jego projekcie dane oraz instrukcje miały być wprowadzane za pomocą kart perforowanych, a wyniki - drukowane lub zapisywane na kartach perforowanych w celu możliwości dalszego przetwarzania. Choć maszyna Babbage'a nigdy nie została w pełni zrealizowana, wyznaczyła kierunek dla późniejszego rozwoju informatyki: automatyzacji przetwarzania informacji oraz poszukiwania sposobów na bardziej bezpośrednią interakcję z maszyną. Pierwsze komputery XX wieku były urządzeniami zarezerwowanymi dla specjalistów. Programowanie wymagało manualnego łączenia przewodów i ustawiania przełączników. Podstawową barierą komunikacyjną stanowiła różnica między symbolicznym językiem człowieka a binarną reprezentacją danych w komputerze. Każda interakcja była czasochłonna i obca ludzkiej intuicji. W drugiej połowie lat 50. XX wieku pojawiły się pierwsze próby połączenia komputerów z maszynami do pisania. Jednym z pionierskich rozwiązań był IBM 610, który jako jeden z pierwszych komputerów wykorzystywał klawiaturę do wprowadzania danych [1]. W połączeniu z interfejsem tekstowym, doprowadziło to do popularyzacji klawiatur jako urządzeń wejściowych oraz rozwoju języków programowania.

W miarę jak komputery stawały się coraz bardziej dostępne, wzrastało zapotrzebowanie na bardziej intuicyjne sposoby interakcji z nimi. Klawiatura i interfejs tekstowy umożliwiły użytkownikowi komunikację za pomocą języka pisanego, lecz wciąż była to forma symboliczna, daleka od naturalnych działań człowieka w świecie fizycznym. Przełom nastąpił w latach 60., kiedy amerykański badacz Douglas Engelbart opracował w Stanford Research Institute pierwszy prototyp myszy komputerowej [16]. Urządzenie wykonane z drewna, wyposażone w dwa metalowe kółka, pozwalało użytkownikowi wskazywać i manipulować obiektami na ekranie w sposób przypominający ruch ręki po powierzchni stołu. W 1968 roku Engelbart zaprezentował swój wynalazek podczas słynnej prezentacji „The Mother of All Demos", w której po raz pierwszy pokazano także działające okna, hiperłącza i współpracę online w czasie rzeczywistym. Demonstracja ta stała się punktem zwrotnym w historii interfejsów użytkownika, wyznaczając kierunek rozwoju ku środo-

wiskom graficznym. Idea Engelbarta, rozwinięta później przez ośrodki badawcze Xerox PARC [38] i komercyjnie wdrożona przez firmę Apple w latach 80., doprowadziła do powstania współczesnych interfejsów graficznych (GUI). Od tamtego momentu zamiast tylko wydawać abstrakcyjne polecenia w terminalu człowiek mógł również manipulować obiektami na ekranie.

1.1 Komunikacja z komputerem w dzisiejszych czasach

Współczesny świat zdominowany jest przez urządzenia komputerowe, które stały się nieodłącznym elementem codziennego życia. Przełomowym momentem w rozwoju technologii interakcji człowieka z maszyną był rok 2007, kiedy firma Apple zaprezentowała iPhone'a - pierwszy smartfon w pełni oparty na ekranie dotykowym [2]. Choć sama idea dotykowej obsługi urządzeń nie była nowa, to właśnie w tym okresie rozpoczęła się jej masowa popularyzacja. Już wcześniej ekrany dotykowe znajdowały zastosowanie w terminalach, bankomatach i specjalistycznych panelach sterujących, jednak dopiero rozwój elektroniki użytkowej uczynił je standardem. Warto dodać, że początki technologii ekranów dotykowych sięgają lat sześćdziesiątych XX wieku [27].

W konstrukcji ekranów dotykowych stosuje się kilka odmiennych zasad działania. Najstarsze z nich wykorzystywały zjawisko zmiany oporu elektrycznego pomiędzy przezroczystymi warstwami przewodzącymi. Rozwiązania tego typu, nazywane ekranami rezystancyjnymi, pozwalały na obsługę przy użyciu dowolnego przedmiotu, w tym rysika, lecz cechowały się mniejszą precyzją i niższą odpornością mechaniczną. W późniejszych latach opracowano technologie oparte na przerwaniu wiązki podczerwieni emitowanej przez diody rozmieszczone na krawędziach ekranu oraz na zaburzeniu fali akustycznej rozchodzącej się po jego powierzchni (technologia *Surface Acoustic Wave*, SAW). Technologia detekcji w podczerwieni znalazła zastosowanie nie tylko w ekranach dotykowych, ale również w innych interfejsach użytkownika, takich jak kontroler ruchu konsoli Nintendo Wii. W tym rozwiązaniu optyczny czujnik w pilocie odczytywał pozycję dwóch diod podczerwonych w tzw. sensor barze, a dane z czujników inercyjnych (akcelerometrów i żyroskopu) umożliwiały precyzyjne odwzorowanie ruchu w trzech wymiarach. Największą popularność zdobyły jednak ekrany pojemnościowe, które działają na zasadzie zmiany pola elektrostatycznego w miejscu kontaktu z przewodzącym materiałem, takim jak ludzka skóra. Umożliwiają one precyzyjną i płynną obsługę, a także wykrywanie wielu punktów dotyku jednocześnie (funkcja *multi-touch*). Ich podstawową wadą jest brak reakcji na przedmioty nieprzewodzące prądu, co uniemożliwia obsługę w rękawiczkach lub za pomocą tradycyjnego rysika. Pomimo wyższych kosztów produkcji, technologia pojemnościowa niemal całkowicie zastąpiła wcześniejsze rozwiązania i obecnie stanowi standard w smartfonach, tabletach oraz panelach sterujących.

Kolejnym etapem rozwoju metod interakcji człowieka z komputerem stały się interfejsy bezdotykowe, wykorzystujące rozpoznawanie gestów, mowy, ruchu ciała lub kierunku spojrzenia użytkownika. Rozwiązania tego typu umożliwiają komunikację z urządzeniem bez fizycznego kontaktu, co znacząco zwiększa intuicyjność obsługi i poszerza zakres możliwych zastosowań. Przykładem takiej technologii jest system *Microsoft Kinect*, który po raz pierwszy został zaprezentowany w 2010 roku jako urządzenie peryferyjne dla konsoli Xbox 360. System ten wykorzystywał zestaw kamer, czujników głębi oraz

mikrofonów do analizy pozycji ciała, gestów i poleceń głosowych użytkownika w czasie rzeczywistym. Dzięki temu możliwe było sterowanie grami i aplikacjami za pomocą ruchu rąk, tułowia czy komend głosowych, bez konieczności używania tradycyjnego kontrolera. Wprowadzenie technologii głębi 3D umożliwiło również śledzenie przestrzenne wielu użytkowników jednocześnie, co stanowiło istotny krok w kierunku bardziej naturalnej interakcji z systemami komputerowymi.

Najbardziej naturalną formą komunikacji człowieka z otoczeniem jest mowa, dlatego też próby jej wykorzystania jako środka sterowania komputerem rozpoczęto już w latach pięćdziesiątych XX wieku. W 1952 roku K. H. Davis, R. Biddulph i S. Balashek opracowali pierwszy system zdolny do rozpoznawania wypowiadanych cyfr [13]. W kolejnych dekadach rozwój tej technologii koncentrował się na systemach ograniczonych słownikowo lub dostosowanych do konkretnego użytkownika, co pozwalało zwiększyć dokładność rozpoznawania w warunkach ograniczonej mocy obliczeniowej. Rozpoznawanie mowy jest zagadnieniem złożonym, ponieważ wymaga analizy sygnału akustycznego oraz jego interpretacji językowej. Zmienność głosu, akcentu, tempa mówienia czy obecność zakłóceń sprawiają, że stworzenie uniwersalnego systemu zdolnego do rozumienia mowy potocznej stanowi duże wyzwanie. Współczesne rozwiązania wykorzystują jednak zaawansowane modele akustyczne i językowe oparte na sztucznych sieciach neuronowych, co pozwoliło znacząco zwiększyć dokładność i naturalność interakcji głosowej.

Technologie rozpoznawania mowy znajdują zastosowanie przede wszystkim w sterowaniu urządzeniami oraz w transkrypcji tekstu mówionego. Coraz częściej pełnią także rolę narzędzia komunikacji, umożliwiając porozumiewanie się osób mówiących w różnych językach w czasie rzeczywistym. Powszechne stały się systemy asystentów głosowych, takich jak Siri, Alexa czy Google Assistant, które pozwalają wykonywać polecenia, wyszukiwać informacje i sterować inteligentnymi urządzeniami domowymi przy użyciu komend słownych. Rozwiązania te stanowią ważny krok w kierunku bardziej naturalnej komunikacji z komputerem, przybliżając ją do sposobu, w jaki ludzie porozumiewają się ze sobą.

W idealnym świecie człowiek nie musiałby wydawać poleceń komputerowi - maszyna sama wiedziałaby, co chcemy osiągnąć, jakby czytała nasze myśli. Choć wizja ta pozostaje w sferze science fiction, jej częściowe realizacje istnieją już w świecie rzeczywistym. Obecnie największym ograniczeniem interfejsów BCI jest stosunkowo niska szybkość komunikacji. Mimo to systemy te znalazły zastosowanie w psychologii, technikach multimedialnych, wojskowości, a przede wszystkim w medycynie. Tam stanowią często jedyny sposób komunikacji ze światem zewnętrznym dla osób dotkniętych poważnymi chorobami neurologicznymi - takimi jak stwardnienie zanikowe boczne, udary mózgu czy urazy rdzenia kręgowego - które stopniowo ograniczają kontrolę nad ruchem ciała. W takich przypadkach interfejs mózg-komputer pozwala nie tylko na podstawową komunikację, ale również na sterowanie protezami, wózkiem inwalidzkim czy inteligentnym domem.

1.2 Zastosowania interfejsów mózg-komputer

Interfejsy mózg-komputer znajdują zastosowanie w wielu dziedzinach. Ich rozwój koncentruje się głównie na umożliwieniu osobom z niepełnosprawnościami komunikacji oraz kontroli urządzeń. W medycynie systemy BCI są wykorzystywane do przywracania funk-

cji ruchowych u pacjentów z paraliżem, umożliwiając sterowanie protezami kończyn lub wózkami inwalidzkimi za pomocą myśli [24]. Ponadto BCI jest wykorzystywane w celu wspomagania komunikacji osób z zespołem zamknięcia (locked-in syndrome), które nie mogą poruszać się ani mówić. Dzięki analizie sygnałów EEG możliwe jest rozpoznawanie intencji ruchu, co pozwala na wykonywanie prostych czynności, takich jak poruszanie kursorem lub wybór znaków na wirtualnej klawiaturze.

Jednym z wielu obszarów zastosowań jest neurorehabilitacja, gdzie BCI wspomagają procesy odzyskiwania funkcji motorycznych po udarach mózgu lub urazach rdzenia kręgowego. Systemy te wykorzystują neuroplastyczność mózgu, umożliwiając pacjentom ćwiczenie kontrolowanych ruchów poprzez wizualizację i sprzężenie zwrotne [14]. W praktyce BCI często integruje się z egzoszkieletami lub systemami funkcjonalnej stymulacji elektrycznej (FES), co pozwala na bezpośrednie wspomaganie wykonywanych ruchów. Badania kliniczne potwierdzają skuteczność takiego podejścia - w badaniu Frolova i in. zastosowanie egzoszkieletu sterowanego poprzez wyobrażenie ruchu doprowadziło do istotnej poprawy funkcji ręki u pacjentów po udarze w porównaniu z grupą kontrolną [18]. Podobne wyniki uzyskano w eksperymencie Bundy'ego i współpracowników, gdzie uczestnicy sterowali egzoszkieletem kończyny górnej za pomocą sygnałów EEG z nieuszkodzonej półkuli, co przełożyło się na wzrost aktywności korowej i poprawę wyników testów motorycznych [9]. Takie zamknięte pętle treningowe mogą zwiększać aktywność korową i przyspieszać odzyskiwanie kontroli motorycznej, szczególnie przy intensywnym i spersonalizowanym treningu. Efektywność terapii zależy jednak od stopnia uszkodzenia, czasu od urazu oraz dopasowania protokołu rehabilitacyjnego.

Coraz większe znaczenie zyskują także zastosowania poznawcze i badawcze, obejmujące analizę uwagi, zmęczenia czy emocji użytkownika. W takich przypadkach BCI służy do oceny stanu psychofizjologicznego w czasie rzeczywistym, co może być użyteczne np. w transporcie, wojsku lub podczas złożonych zadań wymagających wysokiej koncentracji.

1.3 Struktura interfejsu mózg-komputer

Podstawowa struktura interfejsu mózg-komputer (BCI) została opracowana w latach 70. XX wieku wraz z pracami Jacquesa Vidala, który wprowadził pojęcie BCI i przeprowadził pierwsze eksperymenty umożliwiające sterowanie kursorem lub robotem przy użyciu sygnałów EEG [50, 51]. System BCI składa się z kilku kluczowych etapów przetwarzania sygnału. Pierwszym jest rejestracja aktywności mózgu, najczęściej przy użyciu EEG. Zarejestrowane sygnały wymagają wstępnego oczyszczenia - filtracji zakłóceń fizjologicznych i technicznych - oraz ekstrakcji cech, czyli wyodrębnienia parametrów najbardziej istotnych do interpretacji intencji użytkownika. W tym celu stosuje się filtry dolno- i górnoprzepustowe oraz filtry pasmozaporowe (notch filter). Kolejnym krokiem jest klasyfikacja tych cech przy użyciu algorytmów uczenia maszynowego, który pozwala na przypisanie im określonych komend lub decyzji. Ostatni moduł systemu tłumaczy sygnały mózgowe na konkretne działania, takie jak ruch kursora, sterowanie protezą czy wózkiem inwalidzkim. Na rysunku 1.1 przedstawiono schemat działania interfejsu mózg-komputer. Centralnym elementem całego systemu pozostaje komputer, który analizuje, klasyfikuje sygnały oraz generuje sprzężenie zwrotne, tworząc zamkniętą pętlę komunikacyjną między mózgiem a urządzeniem wykonawczym [3, 54].

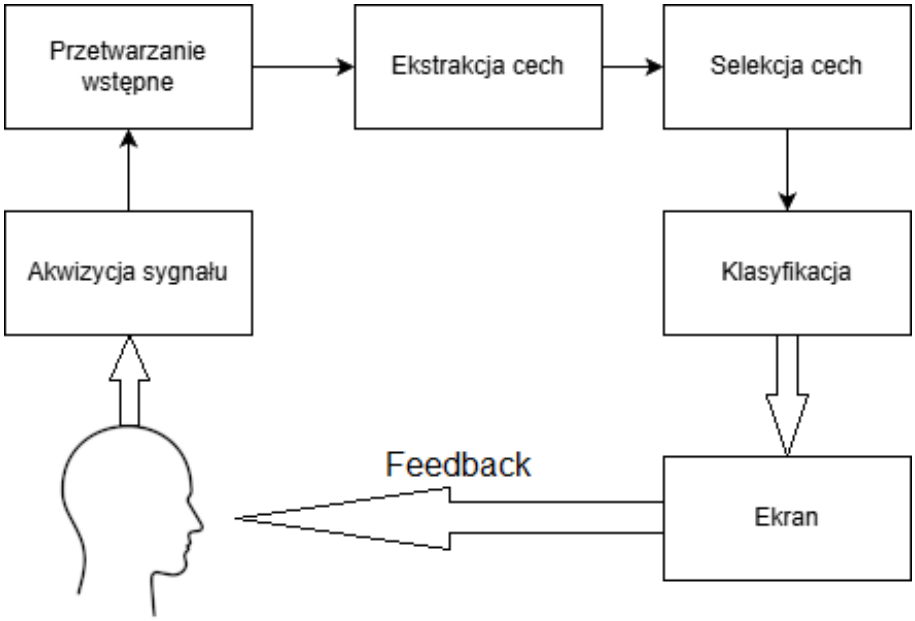

Rysunek 1.1: Schemat struktury interfejsu mózg-komputer (Źródło: opracowanie własne na podstawie [28])

1.4 Metody badania aktywności mózgu

Aby interfejs mózg-komputer mógł działać, niezbędne jest poznanie i rejestracja aktywności elektrycznej mózgu. Istnieje wiele technik badania pracy mózgu, różniących się stopniem inwazyjności, dokładnością i zastosowaniami [22, 41]. Metody inwazyjne obejmują implantowane elektrody domózgowe (IntraCortical Recordings, IR), które pozwalają na bezpośrednie odczytywanie sygnałów neuronów z bardzo wysoką rozdzielczością czasową i przestrzenną. Ich zastosowanie ogranicza jednak wysoki stopień ingerencji chirurgicznej i związane z tym ryzyko. Metody częściowo inwazyjne, takie jak elektrokortykografia (Electrocorticography, ECoG), wykorzystują elektrody umieszczane na powierzchni kory mózgowej. Dają one lepszą jakość sygnału niż metody nieinwazyjne, przy mniejszym ryzyku niż pełne implanty. Metody nieinwazyjne nie wymagają ingerencji chirurgicznej i są bezpieczne do wielokrotnych pomiarów u zdrowych osób. Należą do nich:

- Magnetoencefalografia (MEG) - rejestruje pola magnetyczne generowane przez aktywność neuronów
- Funkcjonalny rezonans magnetyczny (fMRI) - mierzy zmiany przepływu krwi w mózgu jako wskaźnik aktywności neuronów
- Tomografia optyczna (NIRS) - wykorzystuje bliską podczerwień do pomiaru przepływu krwi i saturacji tlenu w tkankach mózgowych.
- Pozytronowa tomografia emisyjna (PET) - pozwala śledzić metabolizm i przepływ krwi
- Elektroencefalografia (EEG) - rejestruje elektryczną aktywność mózgu za pomocą elektrod umieszczonych na skórze głowy

Choć istnieje kilka metod nieinwazyjnego badania aktywności mózgu, tylko niektóre

nadają się do zastosowania w systemach BCI codziennego użytku. Techniki takie jak MEG, PET, fMRI czy tomografia optyczna oferują precyzyjną lokalizację aktywnych obszarów mózgu, jednak są kosztowne, wymagają skomplikowanego sprzętu i specjalistycznej obsługi. Co więcej, mierzą pośrednie efekty aktywności neuronów, takie jak zmiany przepływu krwi, które zachodzą znacznie wolniej niż rzeczywiste impulsy nerwowe, ograniczając szybkość interakcji. Elektroencefalografia za to, przeciwnie, pozwala rejestrować aktywność mózgu w czasie rzeczywistym, jest stosunkowo tania i łatwa w użyciu. Dzięki temu systemy BCI oparte na EEG mogą działać w różnych warunkach, a po krótkim przeszkoleniu użytkownika - nawet w domu. To czyni EEG najbardziej praktycznym wyborem do interfejsów mózg-komputer. Wadą tego rozwiązania jest niski stosunek sygnału do szumu, wynikający z podatności na zakłócenia fizjologiczne (np. napięcie mięśniowe, ruchy oczu) i techniczne (zakłócenia sieci elektrycznej). Sygnał EEG odzwierciedla zbiorową aktywność dużych grup neuronów, co sprawia, że pomiar jest obarczony naturalnymi ograniczeniami dokładności. W odróżnieniu od pomiarów technicznych, gdzie obserwowany parametr istnieje wprost, w biologii sam obiekt pomiaru bywa mniej jednoznaczny. Z tego powodu pojedyncza rejestracja EEG rzadko dostarcza pełnej informacji, a wiarygodne wyniki wymagają wielokrotnych powtórzeń i zastosowania analizy statystycznej. Pomimo tych ograniczeń, sygnał EEG dostarcza cennych danych o stanie funkcjonalnym mózgu. Analiza jego struktury czasowo-częstotliwościowej pozwala wyróżnić charakterystyczne wzorce aktywności neuronalnej, zwane rytmami EEG, które stanowią podstawę interpretacji i wykorzystania sygnału w systemach BCI.

1.5 Pomiar sygnału EEG

Do rejestracji sygnału EEG stosuje się zestaw elektrod przytwierdzanych do skóry głowy, zazwyczaj z użyciem przewodzącego żelu. Elektrody te wychwytują aktywność elektryczną mózgu, która następnie jest wzmacniana i przetwarzana w formę cyfrową przez elektroencefalograf. Urządzenie to mierzy różnice potencjałów między elektrodami umieszczonymi na głowie. Sygnały te są bardzo słabe - ich amplituda nie przekracza kilkudziesięciu mikrovoltów - dlatego niezbędne jest zastosowanie wzmacniaczy. Po wzmocnieniu sygnał jest próbkowany i zapisywany w postaci cyfrowej, co umożliwia jego dalszą analizę.

Rozmieszczenie elektrod na głowie odbywa się według tzw. międzynarodowego systemu 10-20, opracowanego przez Herberta Jaspera w 1958 roku. System ten określa pozycje elektrod w oparciu o odległości pomiędzy charakterystycznymi punktami anatomicznymi czaszki: nasadą nosa (*nasion*), guzowatością potyliczną (*inion*) oraz punktami przeduszno-skroniowymi [25]. Odległości między sąsiednimi elektrodami stanowią odpowiednio 10% lub 20% całkowitej długości wybranego wymiaru głowy, co zapewnia powtarzalność i porównywalność pomiarów między badaniami. Każda elektroda oznaczona jest literą odpowiadającą regionowi mózgu, nad którym się znajduje (F - czołowy, C - centralny, P - ciemieniowy, O - potyliczny, T - skroniowy) oraz cyfrą: nieparzyste numery odnoszą się do lewej półkuli, a parzyste do prawej. Punkt środkowy oznacza się literą „z” (od ang. *zero line*), np. Fz lub Cz. W praktyce standardowy zestaw EEG obejmuje od 19 do 21 elektrod, jednak w badaniach naukowych często stosuje się systemy o większej gęstości (np. 10-10 lub 10-5), zawierające nawet kilkaset elektrod, co pozwala na dokładniejsze odwzorowanie przestrzennego rozkładu aktywności mózgu. Na rysunku

1.2 przedstawiono schemat rozmieszczenia elektrod w standardowym systemie 10-20.

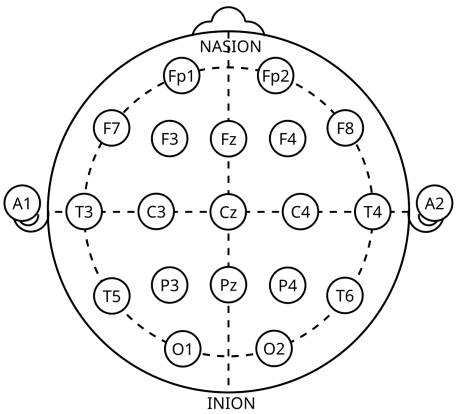

Rysunek 1.2: Rozmieszczenie elektrod na powierzchni głowy w standardowym systemie 10-20 stosowanym w elektroencefalografii

Elektrody EEG mogą być wykonane z różnych materiałów przewodzących, takich jak srebro, chlorek srebra (Ag/AgCl) czy złoto. Najczęściej stosuje się elektrody Ag/AgCl ze względu na ich stabilność potencjału i odporność na dryft napięcia. W zależności od sposobu montażu wyróżnia się elektrody przyklejane, żelowe, suche oraz półsuche. Elektrody suche eliminują konieczność użycia żelu przewodzącego, co zwiększa wygodę użytkownika, ale często wiąże się z większym szumem kontaktowym i mniejszą jakością rejestracji.

Typowy system EEG obejmuje również elektrodę odniesienia (*reference electrode*) oraz elektrodę uziemiającą (*ground electrode*). Elektroda odniesienia stanowi punkt odniesienia potencjałów mierzonych przez pozostałe elektrody i może być umieszczona np. na małżowinie usznej lub w punkcie Cz. Sposób wyboru elektrody odniesienia ma istotny wpływ na kształt i interpretację zarejestrowanego sygnału, dlatego w analizie EEG często stosuje się techniki przeliczeniowe, np. odniesienie wspólne lub tzw. *average reference*, w którym od każdego kanału odejmuje się średnią wartość sygnałów ze wszystkich elektrod. Współczesne elektroencefalografy umożliwiają rejestrację wielu kanałów jednocześnie (od 8 do nawet 256), a także integrację z innymi systemami pomiarowymi, np. śledzenia wzroku, EMG czy EKG. Urządzenia te coraz częściej wykorzystują technologie bezprzewodowe, co zwiększa mobilność i umożliwia prowadzenie pomiarów poza laboratorium. Dzięki postępowi w miniaturyzacji elektroniki, przenośne zestawy EEG stają się coraz powszechniejsze również w zastosowaniach domowych, edukacyjnych i rozrywkowych.

1.6 Rytmy EEG

Rejestrowany sygnał EEG ma bardzo małą amplitudę - zwykle od kilku do kilkudziesięciu μV i jest silnie narażony na zakłócenia. Źródłem szumów mogą być zarówno czynniki zewnętrzne, jak zakłócenia sieciowe o częstotliwości 50 Hz (lub 60Hz) czy urządzenia elektryczne w otoczeniu, jak i wewnętrzne, takie jak ruchy mięśni twarzy, napięcie mięśni czoła, ruchy gałek ocznych czy sygnały z serca. W praktyce zakłócenia te często osiągają amplitudy wielokrotnie większe niż właściwy sygnał mózgowy, co wymaga stosowania

zaawansowanych metod filtracji i przetwarzania. Mimo to, analiza EEG pozwala na identyfikację charakterystycznych wzorców aktywności mózgu, zwanych rytmami lub falami. Są to sygnały o względnie regularnej strukturze i określonym zakresie częstotliwości, które odzwierciedlają stan funkcjonalny mózgu. Wyróżnia się pięć głównych rytmów: delta, theta, alfa, beta i gamma. Ich parametry mogą się różnić w zależności od wieku, stanu psychicznego oraz fizjologicznego badanego. Na rysunku 1.3 przedstawiono przykładowe sygnały poszczególnych rytmów EEG.

Rytm delta (0,5-4 Hz)

Rytmy delta występują w najniższym zakresie częstotliwości. Są charakterystyczne dla snu głębokiego i stanów utraty świadomości. U dorosłych pojawienie się fal delta w stanie czuwania może wskazywać na nieprawidłowości w funkcjonowaniu ośrodkowego układu nerwowego. W zapisie EEG dzieci rytmy delta są jednak zjawiskiem fizjologicznym. Typowa amplituda fal delta wynosi około 50 µV, a ich obecność obserwuje się zwykle na obszarze czołowo-centralnym i w stanie relaksu lub snu.

Rytm theta (4-7 Hz)

Rytmy theta wiążą się z obniżonym poziomem czuwania, sennością, marzeniami sennymi oraz wczesnymi fazami snu. Występują także podczas stanów głębokiego relaksu, medytacji czy chwilowego oderwania uwagi od bodźców zewnętrznych. U dorosłych duży udział fal theta w stanie aktywnego czuwania może wskazywać na zaburzenia neurologiczne lub nadmierne zmęczenie. Amplituda tego rytmu nie przekracza zazwyczaj 30 µV. W zapisie EEG fale theta pojawiają się głównie w odprowadzeniach środkowych.

Rytm alfa (8-13 Hz)

Rytmy alfa zostały opisane po raz pierwszy przez Hansa Bergera w 1930 roku i są uznawane za podstawowy wzorzec aktywności mózgu u dorosłych. Występują głównie w stanie spoczynku, przy zamkniętych oczach i braku intensywnego skupienia. Zanik rytmu alfa następuje po otwarciu oczu lub w sytuacji silnego pobudzenia psychicznego. Sygnał ten jest najlepiej widoczny w okolicach potylicznych, czyli nad korą wzrokową. Częstotliwość rytmu alfa mieści się w przedziale 8-13 Hz, a amplituda wynosi zwykle 20-100 µV. Całkowity brak tego rytmu u osoby dorosłej w stanie relaksu może wskazywać na zaburzenia neurologiczne.

Rytm beta (13-30 Hz)

Rytmy beta obejmują fale o wyższych częstotliwościach i mniejszej amplitudzie, które dominują podczas aktywności umysłowej, koncentracji, analizy informacji oraz w trakcie ruchu. Występują głównie w przednich częściach mózgu, szczególnie w rejonach czołowo-centralnych. Rytm beta wykazuje znaczną zmienność amplitudy, co ogranicza jego zastosowanie diagnostyczne. Obserwuje się także asymetrię międzypółkulową, która może mieć znaczenie kliniczne - np. słabsza obecność rytmu beta w jednej półkuli bywa powiązana z zaburzeniami funkcjonalnymi. Część leków, zwłaszcza barbiturany, zwiększa amplitudę i udział fal beta w zapisie EEG.

Rytm gamma (30-70 Hz)

Fale gamma występują w najwyższym zakresie częstotliwości i wiązane są z procesami poznawczymi wyższego rzędu: percepcją, zapamiętywaniem, integracją informacji sensorycznych oraz aktywnością ruchową. Aktywność gamma odzwierciedla szybkie procesy synchronizacji między różnymi obszarami mózgu i jest uznawana za wskaźnik intensywnego przetwarzania informacji. Choć fale te mają niewielką amplitudę, ich analiza dostarcza cennych danych o mechanizmach świadomości i uwagi.

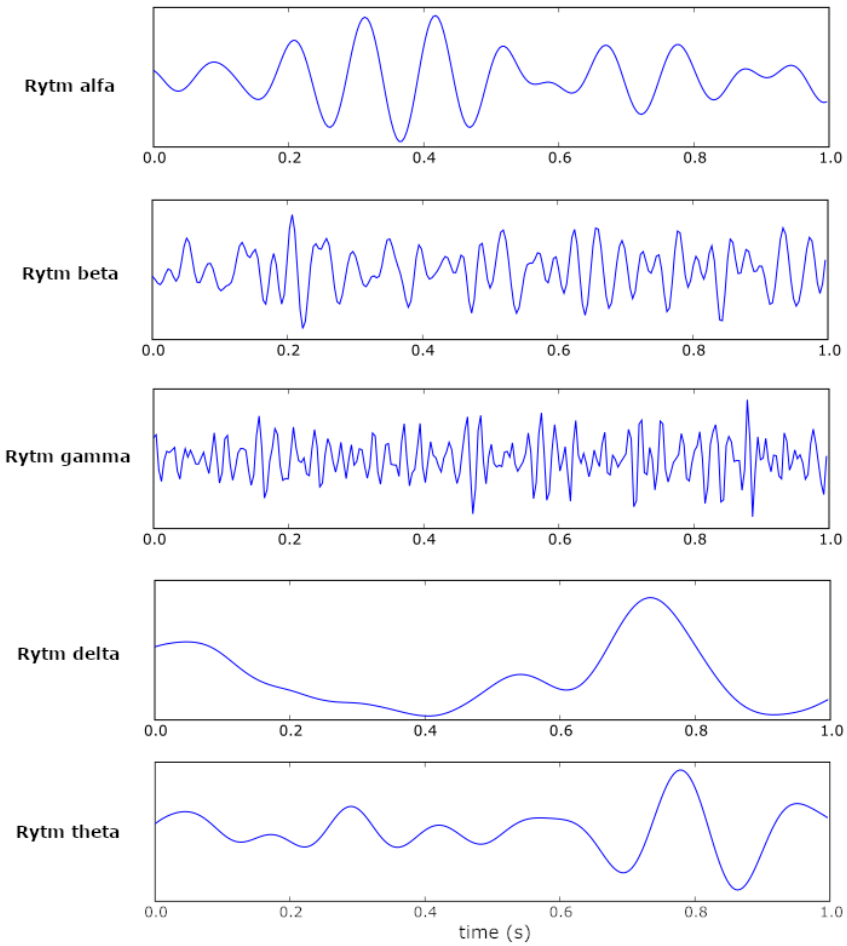

Rysunek 1.3: Próbki sygnałów poszczególnych rytmów EEG [58]

2. Interfejs korzystający z wzrokowych potencjałów wywołanych stanu ustalonego

2.1 Wzrokowe potencjały wywołane stanu ustalonego (SSVEP)

Wzrokowe potencjały wywołane stymulacją o stałej częstotliwości (ang. *Steady-State Visual Evoked Potentials*, SSVEP) są jednym z najbardziej rozpowszechnionych i skutecznych zjawisk wykorzystywanych w systemach BCI [20, 42, 45]. Zjawisko to opiera się na obserwacji bodźców wizualnych migających z określoną częstotliwością. Kiedy użytkownik skupia wzrok na danym bodźcu, w obszarze kory wzrokowej — głównie w okolicach potylicznych — pojawia się rytmiczna aktywność o tej samej częstotliwości, co częstotliwość migotania bodźca, oraz jej wielokrotności [17, 49, 54]. Odpowiedź tę łatwo wykryć w zapisie EEG; cechuje się wysoką powtarzalnością między osobami badanymi. Fizjologiczną podstawą powstawania potencjałów SSVEP jest rezonansowa odpowiedź neuronów kory wzrokowej na rytmiczną stymulację [23, 43, 45, 47].

W typowych systemach BCI opartych na SSVEP stosuje się kilka lub kilkanaście bodźców wizualnych, z których każdy migocze z inną częstotliwością [7, 37]. Użytkownik dokonuje wyboru, skupiając wzrok na wybranym bodźcu, a system analizuje zapis EEG, identyfikując dominującą częstotliwość sygnału. Dużą zaletą SSVEP jest stosunkowo wysoki stosunek sygnału do szumu (SNR) oraz niewielkie wymagania treningowe — użytkownik nie musi opanowywać skomplikowanych strategii mentalnych, jak w przypadku potencjałów ruchowych. Systemy oparte na SSVEP osiągają bardzo wysoką dokładność klasyfikacji (nawet powyżej 95%) i krótki czas reakcji [39]. Należy jednak zauważyć, że metody SSVEP mają również ograniczenia. Wymagają stałej stymulacji wizualnej, co przy dłuższym użytkowaniu może prowadzić do zmęczenia wzroku lub dyskomfortu. Ponadto skuteczność systemu zależy od indywidualnych różnic w czułości na bodźce migające — nie u wszystkich użytkowników uzyskuje się równie silne odpowiedzi [17, 49].

2.2 Struktura interfejsu SSVEP

Interfejs SSVEP składa się z kilku współpracujących modułów, które wspólnie umożliwiają detekcję i interpretację odpowiedzi wzrokowej użytkownika [43, 47]. Pierwszym z nich jest moduł stymulatora, odpowiedzialny za generowanie bodźców wizualnych o określonej częstotliwości i właściwościach fizycznych, takich jak barwa, jasność i kontrast [26, 53]. Kolejnym elementem jest system akwizycji EEG, obejmujący elektrody,

wzmacniacze oraz wstępne filtry, które umożliwiają rejestrację sygnałów elektrycznych generowanych przez korę wzrokową [20, 45]. Zarejestrowany sygnał trafia następnie do modułu przetwarzania i analizy, w którym stosuje się techniki takie jak szybka transformata Fouriera (FFT), analiza korelacji kanonicznej (CCA) oraz analiza korelacji kanonicznej z zastosowaniem banków filtrów (FBCCA), w celu wyodrębnienia komponentów częstotliwościowych odpowiadających konkretnym bodźcom [7, 11, 39]. Wyniki analizy interpretuje moduł klasyfikacji, który identyfikuje bodziec będący obiektem uwagi użytkownika i przekazuje odpowiednią komendę do systemu sterowania lub interfejsu użytkownika [19, 40]. Całość działania wspiera interfejs wizualny lub sterujący, reagujący na wybór użytkownika w czasie rzeczywistym, umożliwiając np. wybór liter, sterowanie obiektami w środowisku wirtualnym lub kontrolę urządzeń zewnętrznych [12, 29]. Funkcjonalny model takiego rozwiązania przedstawiono na rysunku 2.1.

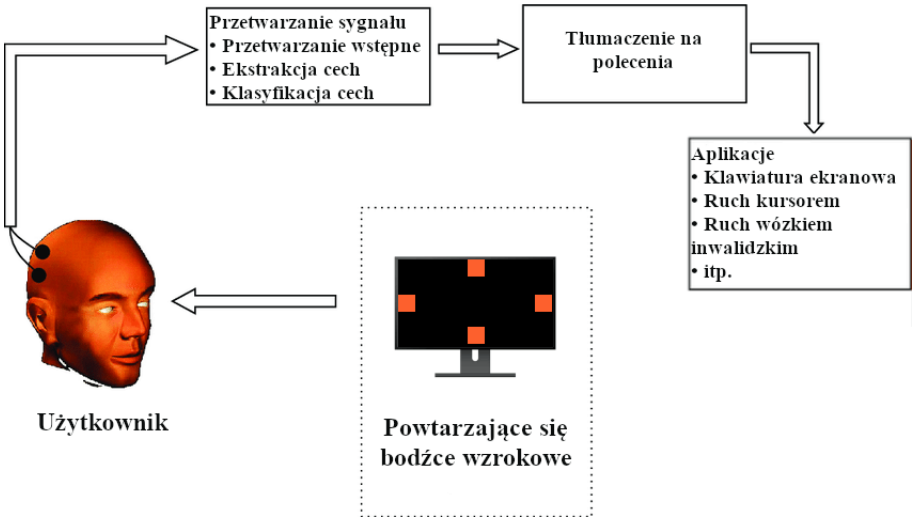

Rysunek 2.1: Funkcjonalny model interfejsu BCI opartego na SSVEP. Opracowanie własne na podstawie: [6].

2.3 Sposoby prezentacji bodźców

Tradycyjnie bodźce w eksperymentach SSVEP prezentuje się na monitorach komputerowych. Precyzyjna kontrola częstotliwości migotania bodźców jest kluczowa, ponieważ odpowiedź EEG uczestnika jest silnie zsynchronizowana z tą częstotliwością. Niedokładna synchronizacja może prowadzić do zniekształceń sygnału i spadku skuteczności detekcji. Starsze ekrany kineskopowe (CRT) umożliwiały bardzo precyzyjną kontrolę częstotliwości odświeżania, sięgającą nawet 160 Hz, w zależności od rozdzielczości i trybu pracy [31, 56]. Pomimo tej zalety, monitory CRT nie są obecnie praktycznym wyborem ze względu na duże rozmiary, masę oraz wysokie zużycie energii.

Współczesne monitory LCD osiągają porównywalne lub wyższe częstotliwości odświeżania przy lepszej rozdzielczości i niższym zapotrzebowaniu energetycznym [52, 55]. Typowy monitor LCD o częstotliwości odświeżania 60 Hz pozwala generować bodźce o częstotliwościach będących dzielnikami tej wartości, np. w zakresie 10-30 Hz [10]. No-

woczesne wyświetlacze z odświeżaniem 120-240 Hz umożliwiają szerszy zakres częstotliwości i gęstsze rozmieszczenie bodźców bez ryzyka nakładania się odpowiedzi SSVEP z różnych źródeł [26, 48]. Przykładowy sposób użycia monitora LCD w interfejsie SSVEP zaprezentowano na rysunku 2.2. Monitory LCD mają jednak ograniczenia wynikające z fizycznych właściwości wyświetlaczy. Czas reakcji pikseli rzędu kilku milisekund może powodować niewielkie opóźnienia w migotaniu bodźców, a przy dużej liczbie bodźców na ekranie możliwe jest nakładanie się odpowiedzi SSVEP w sygnale EEG. Dlatego w eksperymentach SSVEP nie zaleca się używania ekranów, których czas reakcji zwykle przekracza 5 ms. Synchronizacja prezentacji bodźców z klatkami monitora jest dokładniejsza niż korzystanie z timerów systemowych, które mogą powodować niewielkie wahania czasowe. Badania wykazują, że synchronizacja z odświeżaniem monitora pozwala osiągnąć skuteczność generowania bodźców na poziomie około 90% [10]. Dodatkowo stosowanie metod niesymetrycznych lub przesunięcia fazowego umożliwia generowanie częstotliwości pośrednich, zwiększając liczbę dostępnych komend w interfejsach BCI bez konieczności zmiany sprzętu [26, 48].

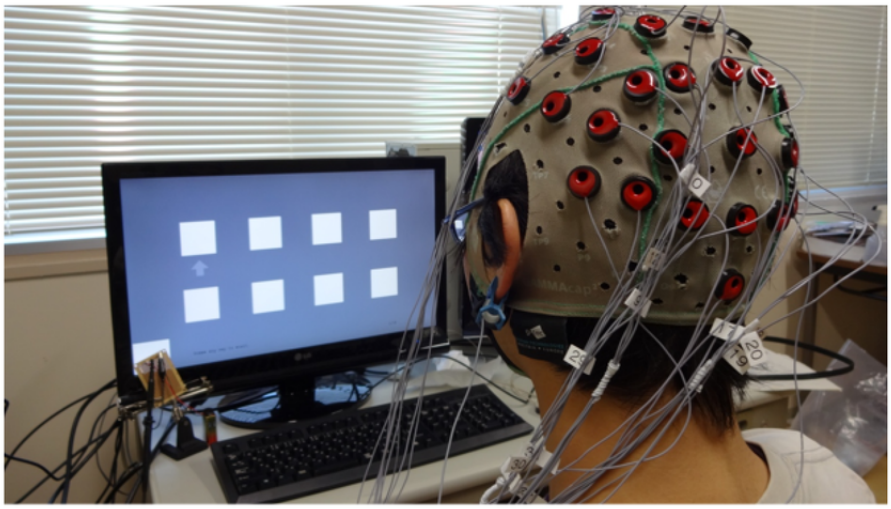

Rysunek 2.2: Przykładowe użycie monitora LCD jako źródła bodźców w eksperymencie SSVEP. Źródło: [8].

Oprócz monitorów LCD, w literaturze szeroko analizowano wpływ rodzaju źródła światła na jakość rejestrowanych potencjałów SSVEP. W szczególności panele z diodami LED wykazują znacznie lepsze właściwości stymulacyjne w porównaniu z wyświetlaczami LCD i CRT [53]. Diody LED charakteryzują się bardzo krótkim czasem reakcji (rzędu mikrosekund), co umożliwia generowanie migotania o niemal dowolnej częstotliwości bez widocznych opóźnień czy nieliniowości. Dzięki temu bodźce są wyświetlane z wysoką precyzją fazową i minimalnym rozmyciem luminancji, co skutkuje większą stabilnością oraz amplitudą rejestrowanych potencjałów [11]. Badania porównawcze wykazały, że stymulacja wzrokowa za pomocą diod LED prowadzi do najwyższych wartości współczynnika SNR oraz amplitudy SSVEP spośród wszystkich testowanych urządzeń [46]. Dla wyższych częstotliwości (15-32 Hz) amplitudy sygnałów generowanych przez panele LED przekraczały dwukrotnie wartości uzyskane dla wyświetlaczy LCD i CRT. Coraz częściej

analizuje się również wykorzystanie ekranów OLED w kontekście SSVEP. Wyświetlacze te oferują doskonały kontrast oraz szeroki zakres odwzorowania barw, jednak ich czas reakcji pikseli i charakter modulacji luminancji ograniczają skuteczność generowania stabilnych potencjałów [46]. W eksperymentach stwierdzono, że dla częstotliwości 32 Hz bodźce prezentowane za pomocą OLED nie wywoływały mierzalnej odpowiedzi SSVEP.

Na jakość potencjałów SSVEP wpływają nie tylko rodzaj wyświetlacza, lecz także parametry samego bodźca. Szczególnie istotne są barwa, kontrast oraz jasność światła. Wykazano, że bodźce niebieskie i zielone generują silniejsze odpowiedzi SSVEP niż bodźce czerwone, co wynika z większej wrażliwości siatkówki na krótsze długości fal [26, 53]. Z kolei zbyt wysoki kontrast lub nadmierna luminancja mogą prowadzić do szybkiego zmęczenia wzroku i obniżenia komfortu użytkownika.

2.4 Akwizycja sygnałów EEG w interfejsach SSVEP

Do akwizycji sygnałów EEG niezbędny jest wielokanałowy system rejestracji. Liczba elektrod zależy od przyjętej strategii pomiarowej, jednak w typowych systemach SSVEP zaleca się stosowanie od 8 do 32 kanałów, szczególnie w obszarze potylicznym i ciemieniowym (np. O1, O2, Oz, POz, Pz), gdzie amplituda odpowiedzi SSVEP jest największa [35]. Elektrody mogą być mokre (z żelem przewodzącym) lub suche; elektrody mokre oferują wyższy stosunek sygnału do szumu i lepszy kontakt elektryczny, natomiast elektrody suche umożliwiają szybsze przygotowanie pomiaru i większy komfort użytkownika kosztem nieco niższej jakości sygnału [36].

Ważnym aspektem jest synchronizacja między systemem stymulacji wizualnej a systemem rejestracji EEG. Bodźce migają z określoną częstotliwością, a precyzyjna synchronizacja gwarantuje, że zarejestrowane sygnały odpowiadają faktycznym momentom prezentacji bodźca. Do synchronizacji wykorzystuje się różne metody, takie jak detekcja sygnału wyjściowego z monitora (np. fotodioda) lub protokoły komunikacyjne o niskim opóźnieniu w przypadku stymulacji VR/AR [39]. Brak dokładnej synchronizacji skutkuje przesunięciami fazowymi i błędną identyfikacją częstotliwości dominujących. Ostatnim etapem jest zapis danych w odpowiednim formacie z uwzględnieniem metadanych: oznaczenia kanałów, częstotliwości próbkowania, momentu rozpoczęcia i zakończenia pomiaru, parametrów filtrów oraz danych kalibracyjnych. Taki zapis umożliwia późniejsze przetwarzanie, analizę harmonicznych i synchronizację z bodźcami.

2.5 Metody przetwarzania wykorzystane w interfejsie SSVEP

Po akwizycji sygnału EEG następuje jego wstępne przetwarzanie, obejmujące filtrowanie pasmowe, usuwanie artefaktów oraz normalizację amplitud. Filtrowanie pasmowe ogranicza sygnał do interesującego zakresu częstotliwości (zwykle 5-50 Hz), redukując zakłócenia niskoczęstotliwościowe oraz szumy wysokoczęstotliwościowe generowane przez mięśnie lub sprzęt [49, 53]. Artefakty ruchowe i zakłócenia sieciowe mogą być dodatkowo tłumione przy użyciu metod takich jak regresja liniowa lub analiza składowych niezależnych (ICA) [32]. Tak przygotowany sygnał trafia do modułu ekstrakcji cech, który identyfikuje komponenty częstotliwościowe odpowiadające konkretnym bodźcom wizualnym.

Przygotowany sygnał EEG dla kanału c można zapisać jako macierz:

$$X_c[n] = F\big(x_c[n]\big), \quad n = 0, 1, \ldots, N-1$$

gdzie $x_c[n]$ to sygnał surowy z kanału c, F oznacza operację filtrowania i normalizacji, a N jest liczbą próbek w analizowanym oknie czasowym.

Analiza w dziedzinie częstotliwości — FFT i PSD

Celem analizy w dziedzinie częstotliwości jest wydobycie informacji o obecności składowych częstotliwościowych odpowiadających bodźcom wzrokowym. W tym celu wykorzystuje się szybką transformację Fouriera (FFT) oraz estymację widmowej gęstości mocy (PSD) [7, 44].

Dla sygnału czasowego $x[n]$, gdzie $n = 0, 1, \ldots, N-1$, dyskretna transformata Fouriera (DFT), będąca podstawą FFT, definiowana jest jako:

$$X[k] = \sum_{n=0}^{N-1} x[n]\, e^{-j2\pi kn/N}, \quad k = 0, 1, \ldots, N-1 \tag{2.1}$$

gdzie:
- $X[k]$ — zespolona wartość widma odpowiadająca częstotliwości dyskretnej f_k,
- $x[n]$ — próbka sygnału w dziedzinie czasu,
- N — liczba próbek w analizowanym oknie,
- i — jednostka urojona, $i^2 = -1$.

Dla sygnałów rzeczywistych, ze względu na symetrię widma, wystarczy analizować tylko lewą połowę widma częstotliwościowego obejmującego prążki, tj. $k = 0, 1, \ldots, N/2$. Częstotliwość odpowiadającą indeksowi k oblicza się ze wzoru:

$$f_k = \frac{k f_s}{N} \tag{2.2}$$

gdzie f_s oznacza częstotliwość próbkowania. Dla $f_s = 512\,\mathrm{Hz}$, zastosowanie 512-punktowej FFT pozwala uzyskać rozdzielczość częstotliwościową równą 1 Hz.

W kontekście systemów SSVEP odpowiedź mózgowa występuje nie tylko na częstotliwości bodźca wzrokowego f_b, lecz również na jej harmonicznych ($2f_b, 3f_b, \ldots$). Dlatego analizuje się całe pasma skupione wokół częstotliwości podstawowej i jej wielokrotności [37]. Na rysunku 2.3 przedstawiono przykładowe widmo FFT sygnału EEG z wyraźnymi prążkami odpowiadającymi bodźcu o częstotliwości 10 Hz.

W praktyce obliczenia przeprowadza się osobno dla sygnału z każdego kanału EEG, wykorzystując przesuwające się okno czasowe długości N. Wybór długości okna stanowi kompromis między rozdzielczością częstotliwościową a zdolnością śledzenia zmian czasowych. Dłuższe okna (2-4 s) zapewniają lepszą rozdzielczość częstotliwościową, ale powodują większe opóźnienie odpowiedzi systemu, natomiast krótsze okna (0,5-1 s) pozwalają na szybsze wykrywanie zmian kosztem precyzji [21]. Dla każdego okna wyznacza się PSD, określającą energię sygnału przypadającą na jednostkę szerokości pasma częstotliwości:

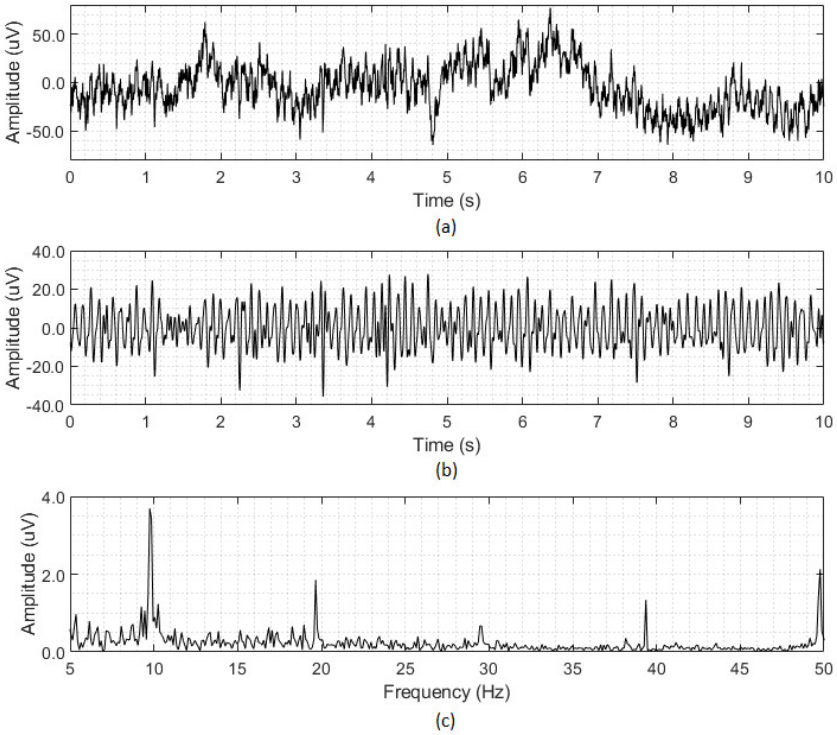

Rysunek 2.3: Przykład SSVEP użytkownika patrzącego na bodziec migający z częstotliwością 10 Hz: EEG w dziedzinie czasu (a); EEG po filtracji w dziedzinie czasu (b); EEG w dziedzinie częstotliwości (c). Źródło: [4].

$$\mathrm{PSD}[k] = \frac{1}{N}|X[k]|^2 \tag{2.3}$$

Wartości $\mathrm{PSD}[k]$ stanowią podstawę dalszej analizy, w której ocenia się, jak silny jest sygnał na częstotliwościach odpowiadających bodźcom wizualnym. Detekcja aktywnego bodźca może opierać się na identyfikacji częstotliwości o najwyższej mocy lub najwyższym stosunku SNR, definiowanym jako:

$$\mathrm{SNR}(f_b) = \frac{|X[k_b]|^2}{\frac{1}{M}\sum_{m\in\mathcal{N}}|X[m]|^2} \tag{2.4}$$

gdzie:

- k_b — indeks częstotliwości bodźca f_b,
- $\mathcal{N}$ — zbiór indeksów sąsiednich prążków reprezentujących tło spektralne,
- M — liczba prążków w zbiorze $\mathcal{N}$.

Częstotliwość bodźca o największym SNR uznaje się za aktualnie obserwowaną w odpowiedzi mózgowej użytkownika. Metoda ta jest prosta, skuteczna i łatwa do implementacji w czasie rzeczywistym, szczególnie w systemach o ograniczonych zasobach

obliczeniowych. Jej główną wadą jest ograniczona odporność na zakłócenia oraz brak wykorzystania informacji przestrzennych między kanałami EEG, dlatego często łączy się ją z technikami CCA lub FBCCA, które lepiej wykorzystują zależności międzykanałowe i zwiększają czułość detekcji bodźców.

2.6 Przykładowe interfejsy SSVEP

Rozwój współczesnych interfejsów SSVEP koncentruje się na redukcji zmęczenia wzrokowego, zwiększeniu komfortu użytkownika oraz integracji z metodami uczenia głębokiego i systemami adaptacyjnymi. Coraz częściej stosuje się także hybrydowe rozwiązania łączące SSVEP z sygnałami EMG lub EOG, umożliwiające bardziej elastyczne sterowanie w złożonych środowiskach interaktywnych.

Jednym z najbardziej znanych interfejsów opartych na SSVEP jest system zaproponowany przez Gao i współpracowników [19], umożliwiający wybór liter na wirtualnej klawiaturze na podstawie częstotliwości migotania poszczególnych pól. Każdy symbol był stymulowany z inną częstotliwością w zakresie 8-15 Hz, a użytkownik, skupiając wzrok na wybranym polu, generował w korze wzrokowej rytmiczną aktywność o tej samej częstotliwości. Detekcja sygnału realizowana była w czasie rzeczywistym metodą CCA, co pozwalało uzyskać dokładność przekraczającą 95% przy czasie integracji 1-2 s. Podobne systemy stanowiły punkt odniesienia dla rozwoju bardziej złożonych interfejsów SSVEP. W polskim środowisku naukowym warto wyróżnić rozwiązania opracowane przez zespół prof. Andrzeja Materki z Politechniki Łódzkiej [33, 34]. Autorzy zaproponowali system SSVEP wykorzystujący naprzemienną stymulację pól wzrokowych, w której prawa i lewa połowa pola widzenia użytkownika były naprzemiennie pobudzane światłem LED. Takie podejście wzmacniało różnice między sygnałami rejestrowanymi z odpowiednich półkul mózgowych. Dodatkowo zastosowano różnicowy pomiar EEG z elektrod rozmieszczonych symetrycznie nad obszarami potylicznymi (O1, O2), co pozwalało eliminować artefakty symetryczne i poprawiało selektywność pomiaru. Naprzemienna stymulacja pól wzrokowych przyspieszała komunikację między użytkownikiem a systemem, znajdując zastosowanie w praktycznych interfejsach, takich jak wirtualna klawiatura umożliwiająca wybieranie numerów telefonu.

Na Uniwersytecie Warszawskim zespół kierowany przez prof. Piotra Durkę opracował interfejs SSVEP z dynamicznie zmieniającym się zestawem bodźców [15]. System był częścią projektu *OpenBCI* i wykorzystywał adaptacyjne menu, w którym elementy zmieniały pozycję i kształt w zależności od wyników wcześniejszych klasyfikacji. Takie rozwiązanie zmniejszało zmęczenie użytkownika i skracało czas potrzebny na wybór właściwej opcji. Interfejs testowano w warunkach zbliżonych do rzeczywistych, z użyciem lekkiego, przenośnego zestawu EEG oraz standardowego monitora LCD jako źródła bodźców. Badania wykazały, że nawet przy niższej jakości sygnału możliwe było uzyskanie stabilnych odpowiedzi SSVEP, co potwierdziło użyteczność tego podejścia w środowiskach nielaboratoryjnych.

Różne grupy badawcze eksperymentowały z alternatywnymi formami bodźców. Bakardjian, Tanaka i Cichocki [5] opracowali interfejs z ośmioma komendami, w którym bodźce realizowano za pomocą diod LED rozmieszczonych w okręgu wokół monitora. System osiągał wysoką stabilność i rozdzielczość częstotliwościową przy niewielkim zużyciu

energii. Inne prace wykorzystywały wzory szachownicowe lub zmieniające się figury geometryczne jako bodźce wzrokowe, co pozwalało uzyskać wyraźniejsze odpowiedzi SSVEP przy mniejszym zmęczeniu wzroku [11]. Kuś i in. [30] zaproponowali połączenie diod LED i bodźców generowanych na ekranie LCD, co umożliwiło zwiększenie liczby możliwych klas przy zachowaniu synchronizacji czasowej między źródłami światła. Systemy Nakanishiego i współpracowników [40] wprowadziły kodowanie częstotliwościowo-fazowe (FPC), w którym bodźce różniły się nie tylko częstotliwością, lecz także fazą początkową, zwiększając liczbę komend przy ograniczonej przestrzeni ekranu. Bodźce rozmieszczano koncentrycznie wokół punktu fiksacji, co zmniejszało obciążenie wzrokowe i poprawiało komfort użytkowania. Systemy te znalazły zastosowanie m.in. w sterowaniu ruchem kursora, pojazdów mobilnych i dronów. W eksperymentach uzyskiwano czasy reakcji poniżej 2 s przy zachowaniu dokładności powyżej 90%, co czyniło je użytecznymi w sterowaniu w czasie rzeczywistym.

Znaczący rozwój interfejsów SSVEP nastąpił wraz z popularyzacją technologii rzeczywistości wirtualnej (VR) i rozszerzonej (AR). Kosmyna i współpracownicy [29] opracowali system integrujący bodźce SSVEP z wirtualnym środowiskiem, w którym użytkownik mógł wybierać elementy menu jedynie wzrokiem. Bodźce renderowano w przestrzeni 3D, utrzymując stałą pozycję względem pola widzenia. Kolejne prace, np. autorstwa Cheng i in., wprowadziły mechanizmy kompensacji dryftu spojrzenia oraz dynamicznego dostosowywania parametrów bodźców do indywidualnych cech użytkownika, co umożliwiło stabilną detekcję w warunkach ruchu i zmiennego oświetlenia [12].

3. Projekt oraz implementacja interfejsu SSVEP

W niniejszym rozdziale przedstawiono główne założenia projektowe oraz ogólną koncepcję implementacji systemu interfejsu mózg-komputer opartego na zjawisku wzrokowych potencjałów wywołanych stanu ustalonego. Celem projektu jest opracowanie rozwiązania umożliwiającego sterowanie kursorem myszy za pomocą odpowiedzi neuronalnych generowanych w odpowiedzi na migoczące bodźce wzrokowe. Konstrukcja systemu musi zapewniać nie tylko funkcjonalność pozwalającą na wykonywanie podstawowych komend ruchu kursora, ale również powtarzalność wyników. Z tego względu nacisk położono na równowagę pomiędzy prostotą konfiguracji a jakością akwizycji sygnału EEG.

3.1 Założenia projektowe

Zdefiniowano dwie grupy wymagań: funkcjonalne, określające możliwości systemu, oraz pozafunkcjonalne, dotyczące jakości i warunków pracy rozwiązania.

Założenia funkcjonalne systemu

- System umożliwia sterowanie kursorem w czterech kierunkach oraz generowanie kliknięcia.
- Użytkownik wybiera komendę poprzez skupienie wzroku na jednym z pięciu migających bodźców.
- System dokonuje analizy sygnału w oknach czasowych o stałej długości.
- Interfejs pozwala na konfigurację parametrów migających pól (kolor, pozycja, częstotliwość).

Założenia pozafunkcjonalne systemu

- Stabilność działania systemu nie zależy od wahań jakości łącza Bluetooth (zastosowanie buforowania).
- Moduł przetwarzania sygnału musi być odporny na typowe zakłócenia sieci energetycznej (50 Hz).
- Aplikacja działa w sposób deterministyczny, zapewniając stałą częstotliwość odświeżania stymulatora.
- System działa w czasie rzeczywistym z opóźnieniem akceptowalnym dla użytkownika.

3.2 Model systemu

Ogólna architektura rozwiązania opiera się na interakcji trzech głównych modułów: modułu stymulującego, modułu rejestracji sygnału oraz modułu przetwarzającego. Schemat ogólny modelu systemu, obrazujący przepływ informacji między użytkownikiem a poszczególnymi blokami, przedstawiono na rysunku 3.1. Moduł stymulujący odpowiada za prezentację bodźców wzrokowych (migających pól), które wywołują specyficzną odpowiedź w mózgu użytkownika. Moduł rejestracji odpowiada za akwizycję biologicznego sygnału EEG. Zarejestrowane dane trafiają do modułu przetwarzającego, gdzie następuje ich filtracja, analiza widmowa oraz klasyfikacja, której wynik jest przekładany na akcję sterującą (ruch kursora).

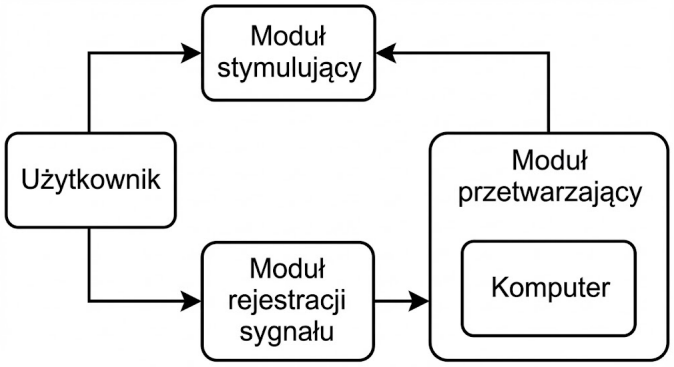

Rysunek 3.1: Model systemu interfejsu SSVEP z podziałem na moduły logiczne.

3.3 Zestaw technologii i proces rejestracji sygnału

Fizyczna realizacja systemu wymagała doboru odpowiednich narzędzi sprzętowych i programistycznych. Do rejestracji sygnału EEG zdecydowano się zastosować moduł OpenBCI Cyton [57], przedstawiony na rysunku 3.2.

Urządzenie to oparte jest na 8-kanałowym wzmacniaczu Texas Instruments ADS1299, 24-bitowym przetworniku analogowo-cyfrowym oraz 8-bitowym mikroprocesorze PIC32MX250F128B firmy Microchip Technology. Komunikacja z jednostką centralną odbywa się bezprzewodowo w standardzie Bluetooth 4.0 przy użyciu dedykowanego dongle'a USB.

Warstwa programowa została zrealizowana w języku Python. Do obsługi interfejsu graficznego i stymulacji wybrano bibliotekę PyQt5. Kluczowym elementem implementacji procesu rejestracji jest wykorzystanie biblioteki **BrainFlow**, która zapewnia uniwersalne API do komunikacji z płytką Cyton. Proces akwizycji danych realizowany jest w pętli głównej programu:

1. Nawiązanie połączenia szeregowego z urządzeniem poprzez port COM.
2. Inicjalizacja sesji i rozpoczęcie strumieniowania danych do bufora wewnętrznego.
3. Cykliczne pobieranie paczki próbek (zgodnej z rozmiarem okna analizy) dla wybranych kanałów EEG.

Dane surowe są przechowywane w strukturach tablicowych biblioteki `numpy`, co umożliwia ich szybkie przetwarzanie numeryczne w kolejnych etapach.

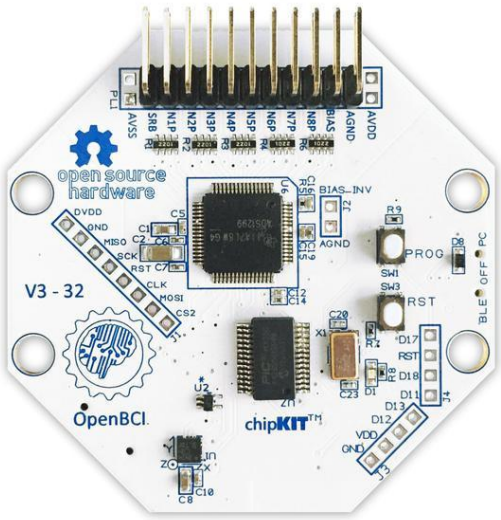

Rysunek 3.2: Urządzenie OpenBCI Cyton wykorzystane w eksperymencie. Źródło: [57]

3.4 Implementacja przetwarzania i klasyfikacji sygnału

Podsystem ten realizuje kluczowe zadania filtracji, transformacji oraz decyzyjności. Dane pobierane są z trzech elektrod zlokalizowanych w punktach O1, O2, Oz (kora wzrokowa) zgodnie z systemem 10-20, elektrody odniesienia na wyrostku sutkowatym oraz elektrody uziemiającej na drugim wyrostku. Wybór tych lokalizacji podyktowany jest fizjologią zjawiska SSVEP, które najsilniej manifestuje się w płacie potylicznym.

Przetwarzanie sygnału i agregacja kanałów

Odebrany sygnał surowy podlega kilkuetapowej obróbce. Ze względu na fakt, że system korzysta z trzech kanałów pomiarowych, konieczne było opracowanie strategii ich agregacji w celu uzyskania jednego, wiarygodnego wyniku klasyfikacji. Zaimplementowano podejście oparte na uśrednianiu w dziedzinie częstotliwości (ang. *spatial averaging*). Proces ten przebiega następująco:

1. **Filtracja wstępna:** Dla każdego kanału niezależnie stosowany jest filtr pasmowo-przepustowy Butterwortha 4. rzędu w zakresie 1–40 Hz oraz filtr notch dla częstotliwości 50 Hz, eliminujący zakłócenia sieci energetycznej.
2. **Transformacja do dziedziny częstotliwości:** Na przefiltrowanym sygnale z każdego kanału wykonywana jest szybka transformata Fouriera.
3. **Uśrednianie widma:** Obliczone widma amplitudowe z trzech kanałów są sumowane i uśredniane.

Takie podejście pozwala na zredukowanie szumu nieskorelowanego między kanałami oraz wzmocnienie wspólnej składowej sygnału wywołanego przez bodziec wzrokowy. Fragment kodu realizujący obliczanie FFT przedstawiono na listingu 3.1.

```
import numpy as np

def compute_fft(x, fs):
```

```
    N = len(x)
    X = np.fft.rfft(x)
    freqs = np.fft.rfftfreq(N, 1/fs)
    return freqs, np.abs(X)
```

Algorytm 3.1: Fragment kodu obliczającego FFT

Na podstawie uśrednionego widma wyznaczany jest estymator gęstości widmowej mocy (PSD). Z obliczonego PSD wyodrębniane są pasma odpowiadające częstotliwościom stymulacji. Algorytm wyznaczania PSD zaprezentowano na listingu 3.2.

```
import numpy as np

def compute_psd(x, fs):
    N = len(x)
    X = np.fft.rfft(x)
    psd = (1/N) * (np.abs(X) ** 2)
    freqs = np.fft.rfftfreq(N, 1/fs)
    return freqs, psd
```

Algorytm 3.2: Fragment algorytmu wyznaczania PSD

Procedura klasyfikacji i stabilizacja decyzji

Klasyfikacja polega na wyznaczeniu stosunku sygnału do szumu (SNR) dla każdej docelowej częstotliwości na podstawie uśrednionego widma PSD. Maksymalna wartość sygnału jest szukana w wąskim paśmie ± 0.5 Hz wokół częstotliwości bodźca, natomiast poziom tła (szumu) estymowany jest z sąsiedztwa tej częstotliwości. Kluczowy fragment logiki klasyfikatora przedstawia listing 3.3.

```
import numpy as np

def compute_snr(freqs, psd, fb, bw=1.0):
    mask_sig = (freqs >= fb - 0.5) & (freqs <= fb + 0.5)
    mask_noise = (freqs >= fb - bw) & (freqs <= fb + bw)
        & (~mask_sig)
    sig = np.mean(psd[mask_sig])
    noise = np.mean(psd[mask_noise])
    return sig / noise

def classify_snr(x, fs, freqs_targets):
    freqs, psd = compute_psd(x, fs)
    scores = {f: compute_snr(freqs, psd, f) for f in
        freqs_targets}
    return max(scores, key=scores.get), scores
```

Algorytm 3.3: Fragment algorytmu klasyfikatora opartego na SNR

Samo wyznaczenie częstotliwości z najwyższym SNR nie jest wystarczające do stabilnego sterowania, ponieważ sygnał EEG jest z natury zaszumiony. W systemie zaimplementowano dodatkowy bufor decyzyjny (ang. *debounce logic*). System uznaje intencję użytkownika tylko wtedy, gdy ta sama częstotliwość zostanie zaklasyfikowana jako

zwycięska (z SNR powyżej progu) przez zadaną liczbę kolejnych okien czasowych (w implementacji przyjęto parametr `REQUIRED_STABILITY = 3`). Dopiero spełnienie tego warunku powoduje wysłanie komendy do modułu sterującego myszą.

3.5 Interfejs użytkownika i wygląd stymulatora

Kluczowym elementem interakcji z użytkownikiem jest moduł stymulujący, zrealizowany przy użyciu biblioteki PyQt5. Został on zaimplementowany w formie nakładki programowej (ang. *overlay*) - bezramkowego, przezroczystego okna, działającego zawsze na wierzchu (flaga `WindowStaysOnTopHint`) i ignorującego bezpośrednie wejście użytkownika (kliknięcia).

Dzięki zastosowaniu biblioteki Qt, rysowanie pól odbywa się wewnątrz zdarzenia `paintEvent`, co pozwala na wysoką wydajność renderowania. Wygląd nakładki przedstawiono na rysunku 3.3. Zdecydowano się na wariant pięciu niezależnych migających pól: cztery pola odpowiadają za sterowanie kierunkowe, natomiast piąte pełni funkcję symulacji kliknięcia.

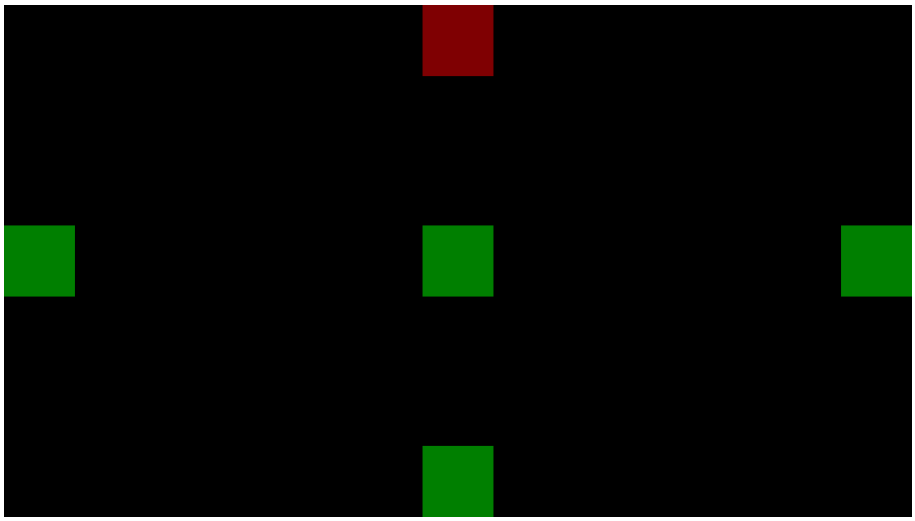

Rysunek 3.3: Zrzut ekranu przedstawiający stymulator. Kolor jednego z pól (aktywnego) został zmieniony na czerwony.

Logika migotania oparta jest na liczniku klatek: widoczność prostokąta jest przełączana, gdy numer klatki osiągnie wartość odpowiadającą półokresowi danej częstotliwości.

Aplikacja umożliwia również szerokie dostosowanie wyglądu stymulatora. Na rysunku 3.4 pokazano okno konfiguracyjne, które pozwala na edycję parametrów takich jak położenie, kolor, rozmiar oraz przezroczystość pól. Opcje te są zapisywane w pliku konfiguracyjnym, co pozwala na szybkie przywrócenie preferencji użytkownika przy kolejnym uruchomieniu.

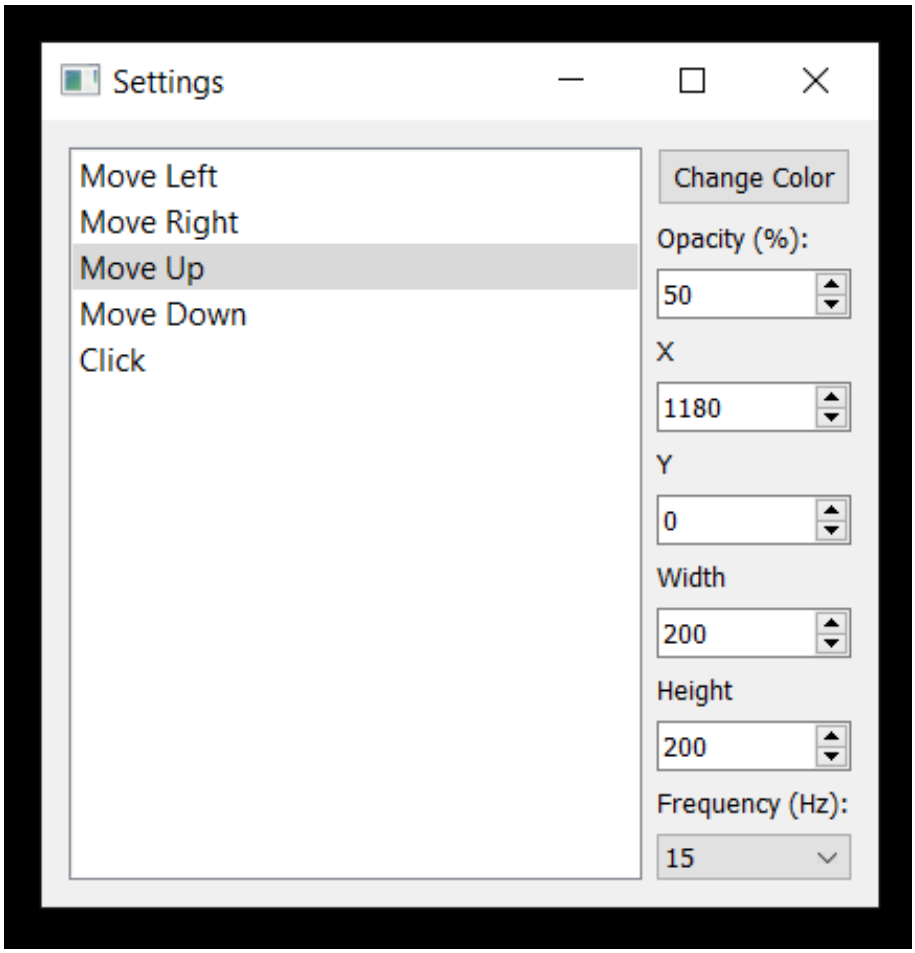

Rysunek 3.4: Okno konfiguracji parametrów wizualnych pól stymulatora.

Podsumowanie

Podsumowanie pracy powinno na maksymalnie dwóch stronach przedstawić główne wyniki pracy dyplomowej. Struktura zakończenia to:

1. Przypomnienie celu i hipotez
2. Co w pracy wykonano by cel osiągnąć (analiza, projekt, oprogramowanie, badania eksperymentalne)
3. Omówienie głównych wyników pracy
4. Jak wyniki wzbogacają dziedzinę
5. Zamknięcie np. poprzez wskazanie dalszych kierunków badań.

Spis literatury

Książki

[1] Martin Campbell-Kelly i William Aspray. *Computer: A History of the Information Machine*. Westview Press, 2009.

[2] Walter Isaacson. *Steve Jobs*. Simon i Schuster, 2011.

[3] J. R. Wolpaw i E. W. Wolpaw. *Brain-Computer Interfaces: Something New Under the Sun*. Oxford University Press, 2012.

Artykuły

[4] Andrea Apicella i in. „Enhancement of SSVEPs Classification in BCI-Based Wearable Instrumentation Through Machine Learning Techniques". W: *IEEE Sensors Journal* (2022).

[5] Hovagim Bakardjian, Toshihisa Tanaka i Andrzej Cichocki. „Optimization of SSVEP brain responses with application to eight-command brain–computer interface". W: *Neuroscience letters* (2010).

[6] Jordi Bieger i Gary Garcia-Molina. „Light Stimulation Properties to Influence Brain Activity: A Brain-Computer Interface Application". W: *Philips Research Technical Note* (2010).

[7] Guangyu Bin i in. „Online and Offline Analysis of the SSVEP-Based Brain-Computer Interface Using Canonical Correlation Analysis". W: *IEEE Transactions on Biomedical Engineering*. 2009.

[8] Andrea Bonci i in. „An Introductory Tutorial on Brain-Computer Interfaces and Their Applications". W: *Electronics* (2021).

[9] D. T. Bundy i in. „Contralesional Brain-Computer Interface Control of a Powered Exoskeleton for Motor Recovery in Chronic Stroke Survivors". W: *Stroke* (2017). URL: `https://pubmed.ncbi.nlm.nih.gov/28550098/`.

[10] H. Cecotti i A. Graeser. „Convolutional neural network with embedded fourier transform for EEG classification". W: *Proceedings of the 19th International Conference on Pattern Recognition (ICPR)* (2010).

[11] X. Chen i in. „Filter bank canonical correlation analysis for implementing a high-speed SSVEP-based brain-computer interface". W: *Journal of Neural Engineering* (2015).

[12] Ming Cheng, Xiaorong Gao i Shangkai Gao. „Design and Implementation of a Real-Time, User-Adaptive SSVEP-Based BCI with Head Movement Compensation". W: *IEEE Transactions on Neural Systems and Rehabilitation Engineering* (2020).

[13] K. H. Davis, R. Biddulph i S. Balashek. „Automatic Recognition of Spoken Digits". W: *Journal of the Acoustical Society of America* (1952).

[14] Bruce H. Dobkin. „Brain-Computer Interface Technology as a Tool to Augment Plasticity and Repair in Central Nervous System Disorders". W: *Current Opinion in Neurology* (2007). URL: `https://pubmed.ncbi.nlm.nih.gov/17992096/`.

[15] Piotr Durka i in. „Open projects for brain-computer interfaces and signal analysis: BCI. fuw. edu. pl and SignalML. org". W: *Frontiers in Neuroinformatics* (2009).

[16] Douglas C. Engelbart i William K. English. „A Research Center for Augmenting Human Intellect". W: *AFIPS Conference Proceedings* (1968).

[17] O. Friman, I. Volosyak i A. Gräser. „Multiple channel detection of steady-state visual evoked potentials for brain-computer interfaces". W: *IEEE Transactions on Biomedical Engineering* (2007).

[18] A. Frolov i in. „Post-stroke rehabilitation training with a motor-imagery-based brain-computer interface (BCI)-controlled hand exoskeleton: a randomized controlled multicenter trial". W: *Frontiers in Neuroscience* (2017). URL: `https://www.frontiersin.org/articles/10.3389/fnins.2017.00400/full`.

[19] Xiaorong Gao i in. „Visual and auditory brain-computer interfaces". W: *IEEE Transactions on Biomedical Engineering* (2014).

[20] C. Guger i in. „Prosthetic control by an EEG-based brain-computer interface (BCI)". W: *Proceedings of the 5th European Conference for the Advancement of Assistive Technology (AAATE)*. 2000.

[21] Christoph Guger i in. „How Many People Could Use an SSVEP BCI?" W: *Frontiers in Neuroscience* (2012).

[22] Haibo He i Dewen Hu. „Brain-Computer Interfaces in Smart Environments: A Review of Recent Advances". W: *IEEE Access* (2019).

[23] C. S. Herrmann. „Human EEG responses to 1–100 Hz flicker: Resonance phenomena in visual cortex and their potential correlation to cognitive phenomena". W: *Experimental Brain Research* (2001).

[24] Leigh R. Hochberg i in. „Reach and grasp by people with tetraplegia using a neurally controlled robotic arm". W: *Nature* (2012). URL: `https://www.nature.com/articles/nature11076`.

[25] Herbert H. Jasper. „Report of the committee on methods of clinical examination in electroencephalography". W: *Electroencephalography and Clinical Neurophysiology* (1958).

[26] C. Jia i in. „Frequency and Phase Mixed Coding in SSVEP-based Brain-computer Interface". W: *IEEE Transactions on Biomedical Engineering* (2010).

[27] E. A. Johnson. „Touch Display — A Novel Input/Output Device for Computers”. W: *Electronics Letters* (1965).

[28] M Kołodziej. „Przetwarzanie, analiza i klasyfikacja sygnału EEG na użytek interfejsu mózg-komputer”. W: *Praca doktorska, Politechnika Warszawska* (2011).

[29] Nataliya Kosmyna, Franck Tarpin-Bernard i Bertrand Rivet. „Bringing BCI and HCI Together: Towards Naturalistic Brain-Computer Interface Paradigms for Human-Computer Interaction”. W: *ACM Transactions on Computer-Human Interaction* (2018).

[30] Rafał Kuś i in. „On the quantification of SSVEP frequency responses in human EEG in realistic BCI conditions”. W: *PloS one* (2013).

[31] Y. Lin, Y. Wang i T.-P. Jung. „Assessing the feasibility of online SSVEP decoding in the presence of auditory stimuli”. W: *Journal of Neural Engineering* (2015).

[32] Scott Makeig i in. „Independent Component Analysis of Electroencephalographic Data”. W: *Advances in Neural Information Processing Systems* (1996).

[33] A Materka i M Byczuk. „Alternate half-field stimulation technique for SSVEP-based brain–computer interfaces”. W: *Electronics Letters* (2006).

[34] Andrzej Materka, Marcin Byczuk i Pawel Poryzala. „A virtual keypad based on alternate half-field stimulated visual evoked potentials”. W: *2007 International Symposium on Information Technology Convergence (ISITC 2007)*. 2007.

[35] K. E. Miller, R. Scherer i G. Pfurtscheller. „Multi-channel classification of single motor-imagined movements for brain-computer interfaces”. W: *Proceedings of the 1st International Conference on Applied Biomedical Engineering*. 2003.

[36] Tim R. Mullen i in. „Real-Time Neuroimaging and Cognitive Monitoring Using Wearable Dry EEG”. W: *IEEE Transactions on Biomedical Engineering* (2015).

[37] S. Müller-Putz i in. „EEG-based neuroprosthesis control: A step towards clinical practice”. W: *Proceedings of the IEEE*. 2008.

[38] Brad A. Myers. „A Brief History of Human-Computer Interaction Technology”. W: *Interactions*. 1998.

[39] M. Nakanishi i in. „Enhancing detection of SSVEPs for a high-speed brain speller using task-related component analysis”. W: *IEEE Transactions on Biomedical Engineering* (2018).

[40] Masaki Nakanishi i in. „A high-speed brain speller using steady-state visual evoked potentials”. W: *International Journal of Neural Systems* (2015).

[41] Luis F. Nicolas-Alonso i Jaime Gomez-Gil. „Brain Computer Interfaces, a Review”. W: *Sensors* (2012).

[42] Luis F. Nicolas-Alonso i Jaime Gomez-Gil. „Brain Computer Interfaces, a Review”. W: *Sensors* (2012).

[43] A. M. Norcia i in. „The steady-state visual evoked potential in vision research: A review”. W: *Journal of Vision* (2015).

[44] Paul L. Nunez i Ramesh Srinivasan. „Electric Fields of the Brain: The Neurophysics of EEG". W: *Oxford University Press* (2006).

[45] G. Pfurtscheller i C. Neuper. „Motor imagery and direct brain-computer communication". W: *Proceedings of the IEEE* (1999).

[46] A. Poryadina, A. Pavlov i A. Kaplan. „The effect of color and contrast of visual stimuli on the strength of SSVEP responses in a BCI paradigm". W: *Sensors* (2022).

[47] D. Regan. „Human brain electrophysiology: Evoked potentials and evoked magnetic fields in science and medicine". W: *Elsevier* (1989).

[48] J. Tong i D. Zhu. „Multi-phase cycle coding for SSVEP based brain-computer interfaces". W: *BioMedical Engineering OnLine* (2015).

[49] F.-B. Vialatte i in. „Steady-state visually evoked potentials: Focus on essential paradigms and future perspectives". W: *Progress in Neurobiology* (2010).

[50] J. J. Vidal. „Toward direct brain-computer communication". W: *Annual Review of Biophysics and Bioengineering* (1973).

[51] J. J. Vidal. „Real-Time Detection of Brain Events in EEG". W: *Proceedings of the IEEE* (1977).

[52] Y. Wang i in. „Visual fatigue in steady-state visual evoked potential based brain-computer interfaces". W: *IEEE Transactions on Neural Systems and Rehabilitation Engineering* (2010).

[53] Yijun Wang, Masaki Nakanishi i Tzyy-Ping Jung. „Visual stimulus design for optimizing SSVEP-based brain-computer interfaces: a review and new perspectives". W: *Frontiers in Human Neuroscience* (2020).

[54] J. R. Wolpaw i in. „Brain-computer interfaces for communication and control". W: *Clinical Neurophysiology* (2002).

[55] Z. Wu i in. „Stimulator selection in SSVEP-based BCI". W: *Medical Engineering and Physics* (2008).

[56] D. Zhu i in. „A Survey of Stimulation Methods Used in SSVEP-Based BCIs". W: *Computational Intelligence and Neuroscience* (2010).

Źródła internetowe i inne

[57] OpenBCI. *OpenBCI - Cyton Board Documentation*. Dostęp: 28.11.2025. URL: `https://docs.openbci.com/Cyton/CytonLanding/`.

[58] Wikipedia. *Fale mózgowe*. Dostęp: 19.10.2025. 2025. URL: `https://pl.wikipedia.org/wiki/Fale_m%C3%B3zgowe`.

Spis rysunków

1.1 Schemat struktury interfejsu mózg-komputer (Źródło: opracowanie własne na podstawie [28]) 13

1.2 Rozmieszczenie elektrod na powierzchni głowy w standardowym systemie 10-20 stosowanym w elektroencefalografii 15

1.3 Próbki sygnałów poszczególnych rytmów EEG [58] 17

2.1 Funkcjonalny model interfejsu BCI opartego na SSVEP. Opracowanie własne na podstawie: [6]. 20

2.2 Przykładowe użycie monitora LCD jako źródła bodźców w eksperymencie SSVEP. Źródło: [8]. 21

2.3 Przykład SSVEP użytkownika patrzącego na bodziec migający z częstotliwością 10 Hz: EEG w dziedzinie czasu (a); EEG po filtracji w dziedzinie czasu (b); EEG w dziedzinie częstotliwości (c). Źródło: [4]. 24

3.1 Model systemu interfejsu SSVEP z podziałem na moduły logiczne. 28

3.2 Urządzenie OpenBCI Cyton wykorzystane w eksperymencie. Źródło: [57] 29

3.3 Zrzut ekranu przedstawiający stymulator. Kolor jednego z pól (aktywnego) został zmieniony na czerwony. 31

3.4 Okno konfiguracji parametrów wizualnych pól stymulatora. 32

A. Dodatek

W dodatkach mogą znaleźć się większe fragmenty kodów źródłowych, instrukcje działania programów, specyfikacje opcji, z którymi wywołuje się program, większe dane tabelaryczne, specyfikacje oprogramowania, dłuższe opisy teoretyczne, itp.

What is Lorem Ipsum? Lorem Ipsum is simply dummy text of the printing and typesetting industry. Lorem Ipsum has been the industry'es standard dummy text ever since the 1500s, when an unknown printer took a galley of type and scrambled it to make a type specimen book. It has survived not only five centuries, but also the leap into electronic typesetting, remaining essentially unchanged. It was popularised in the 1960s with the release of Letraset sheets containing Lorem Ipsum passages, and more recently with desktop publishing software like Aldus PageMaker including versions of Lorem Ipsum.

Why do we use it? It is a long established fact that a reader will be distracted by the readable content of a page when looking at its layout. The point of using Lorem Ipsum is that it has a more-or-less normal distribution of letters, as opposed to using 'Content here, content here', making it look like readable English. Many desktop publishing packages and web page editors now use Lorem Ipsum as their default model text, and a search for 'lorem ipsum' will uncover many web sites still in their infancy. Various versions have evolved over the years, sometimes by accident, sometimes on purpose (injected humour and the like).

Where does it come from? Contrary to popular belief, Lorem Ipsum is not simply random text. It has roots in a piece of classical Latin literature from 45 BC, making it over 2000 years old. Richard McClintock, a Latin professor at Hampden-Sydney College in Virginia, looked up one of the more obscure Latin words, consectetur, from a Lorem Ipsum passage, and going through the cites of the word in classical literature, discovered the undoubtable source. Lorem Ipsum comes from sections 1.10.32 and 1.10.33 of "de Finibus Bonorum et Malorum"(The Extremes of Good and Evil) by Cicero, written in 45 BC. This book is a treatise on the theory of ethics, very popular during the Renaissance. The first line of Lorem Ipsum, "Lorem ipsum dolor sit amet..", comes from a line in section 1.10.32.

The standard chunk of Lorem Ipsum used since the 1500s is reproduced below for those interested. Sections 1.10.32 an

What is Lorem Ipsum? Lorem Ipsum is simply dummy text of the printing and typesetting industry. Lorem Ipsum has been the industry's standard dummy text ever since the 1500s, when an unknown printer took a galley of type and scrambled it to make a type specimen book. It has survived not only five centuries, but also the leap into electronic typesetting, remaining essentially unchanged. It was popularised in the 1960s with the re-

lease of Letraset sheets containing Lorem Ipsum passages, and more recently with desktop publishing software like Aldus PageMaker including versions of Lorem Ipsum.

Why do we use it? It is a long established fact that a reader will be distracted by the readable content of a page when looking at its layout. The point of using Lorem Ipsum is that it has a more-or-less normal distribution of letters, as opposed to using 'Content here, content here', making it look like readable English. Many desktop publishing packages and web page editors now use Lorem Ipsum as their default model text, and a search for 'lorem ipsum' will uncover many web sites still in their infancy. Various versions have evolved over the years, sometimes by accident, sometimes on purpose (injected humour and the like).

Where does it come from? Contrary to popular belief, Lorem Ipsum is not simply random text. It has roots in a piece of classical Latin literature from 45 BC, making it over 2000 years old. Richard McClintock, a Latin professor at Hampden-Sydney College in Virginia, looked up one of the more obscure Latin words, consectetur, from a Lorem Ipsum passage, and going through the cites of the word in classical literature, discovered the undoubtable source. Lorem Ipsum comes from sections 1.10.32 and 1.10.33 of "de Finibus Bonorum et Malorum"(The Extremes of Good and Evil) by Cicero, written in 45 BC. This book is a treatise on the theory of ethics, very popular during the Renaissance. The first line of Lorem Ipsum, "Lorem ipsum dolor sit amet..", comes from a line in section 1.10.32.

The standard chunk of Lorem Ipsum used since the 1500s is reproduced below for those interested. Sections 1.10.32 anWhat is Lorem Ipsum? Lorem Ipsum is simply dummy text of the printing and typesetting industry. Lorem Ipsum has been the industry's standard dummy text ever since the 1500s, when an unknown printer took a galley of type and scrambled it to make a type specimen book. It has survived not only five centuries, but also the leap into electronic typesetting, remaining essentially unchanged. It was popularised in the 1960s with the release of Letraset sheets containing Lorem Ipsum passages, and more recently with desktop publishing software like Aldus PageMaker including versions of Lorem Ipsum.

Why do we use it? It is a long established fact that a reader will be distracted by the readable content of a page when looking at its layout. The point of using Lorem Ipsum is that it has a more-or-less normal distribution of letters, as opposed to using 'Content here, content here', making it look like readable English. Many desktop publishing packages and web page editors now use Lorem Ipsum as their default model text, and a search for 'lorem ipsum' will uncover many web sites still in their infancy. Various versions have evolved over the years, sometimes by accident, sometimes on purpose (injected humour and the like).

Where does it come from? Contrary to popular belief, Lorem Ipsum is not simply random text. It has roots in a piece of classical Latin literature from 45 BC, making it over 2000 years old. Richard McClintock, a Latin professor at Hampden-Sydney College in Virginia, looked up one of the more obscure Latin words, consectetur, from a Lorem Ipsum passage, and going through the cites of the word in classical literature, discovered the undoubtable source. Lorem Ipsum comes from sections 1.10.32 and 1.10.33 of "de Finibus Bonorum et Malorum"(The Extremes of Good and Evil) by Cicero, written in 45 BC. This book is a treatise on the theory of ethics, very popular during the Renaissance.

The first line of Lorem Ipsum, "Lorem ipsum dolor sit amet..", comes from a line in section 1.10.32.

The standard chunk of Lorem Ipsum used since the 1500s is reproduced below for those interested. Sections 1.10.32 an