



Wydział Informatyki

kierunek studiów: Informatyka

specjalność: Inżynieria Oprogramowania

Praca dyplomowa inżynierska

**STEROWANIE KURSOREM MYSZY ZA POMOCĄ
POTENCJAŁÓW WYWOŁYWANYCH STANU USTALONEGO**

**CONTROLLING THE MOUSE CURSOR USING SSVEP EVOKED
POTENTIALS**

Michał Pytkowski

nr albumu: **53961**

Opiekun:

dr hab. Izabela Rejer

Katedra Inżynierii Systemów Informacyjnych

Szczecin, 2026

Streszczenie

Celem pracy jest opracowanie i implementacja aplikacji umożliwiającej bezdotykowe sterowanie kursorem myszy za pomocą sygnałów SSVEP (Steady-State Visual Evoked Potentials). Aplikacja pozwoli na kontrolę ruchu kursora w czterech kierunkach (góra, dół, lewo, prawo) oraz symulowanie kliknięcia lewym przyciskiem myszy. Użytkownik będzie sterował kursorem poprzez skupienie wzroku na wyświetlanych na ekranie polach migających z ustalonymi częstotliwościami. Aplikacja będzie składała się z trzech głównych modułów, obejmujących: moduł do odczytu i przetworzenia sygnału EEG; stymulator ekranowy; oraz moduł sterujący pracą myszki. Praca zostanie wykonana w środowisku Python z wykorzystaniem specjalizowanej biblioteki do odczytu i przetwarzania sygnału EEG (mne).

słowa kluczowe: SSVEP, EEG, interfejs mózg-komputer (BCI), Python

Abstract

The aim of this work is to develop and implement an application enabling touchless mouse cursor control using SSVEP (Steady-State Visual Evoked Potentials) signals. The application will allow for cursor movement control in four directions (up, down, left, right) and simulate left-clicks. The user will control the cursor by focusing their gaze on on-screen fields that flash at predetermined frequencies. The application will consist of three main modules: an EEG signal acquisition and processing module; an on-screen stimulator; and a mouse control module. The work will be implemented in Python using a specialized EEG signal acquisition and processing library (mne).

keywords: SSVEP, EEG, mouse cursor control, brain-computer interface (BCI), Python

Spis treści

Wstęp	7
1 Interfejs mózg-komputer	9
1.1 Komunikacja z komputerem w dzisiejszych czasach	10
1.2 Zastosowania interfejsów mózg-komputer	11
1.3 Struktura interfejsu mózg-komputer	12
1.4 Metody badania aktywności mózgu	13
1.5 Pomiar sygnału EEG	14
1.6 Rytm EEG	15
2 Interfejs korzystający z wzrokowych potencjałów wywołanych stanu ustalonego	19
2.1 Wzrokowe potencjały wywołane stanu ustalonego (SSVEP)	19
2.2 Struktura interfejsu SSVEP	19
2.3 Sposoby prezentacji bodźców	20
2.4 Akwizycja sygnałów EEG w interfejsach SSVEP	22
2.5 Metody przetwarzania wykorzystane w interfejsie SSVEP	22
2.6 Przykładowe interfejsy SSVEP	24
3 Projekt oraz implementacja interfejsu SSVEP	27
3.1 Założenia projektowe	27
3.2 Model systemu	28
3.3 Zestaw technologii i proces rejestracji sygnału	28
3.4 Implementacja przetwarzania i klasyfikacji sygnału	29
3.5 Interfejs użytkownika i wygląd stymulatora	31
4 Przeprowadzenie badania i omówienie wyników	35
4.1 Protokół badania	35
4.2 Wyniki badania	35

4.3	Wyniki ankiety	37
4.4	Dyskusja wyników	38
	Podsumowanie	40
	Spis literatury	43
	Książki	43
	Artykuły	43
	Źródła internetowe i inne	46
A	Protokół badania	47
B	Ankieta oceny systemu	49

Wstęp

Rozwój technologii komputerowych nieustannie przesuwa granice możliwości interakcji człowieka z maszyną. Tradycyjne urządzenia wejściowe — klawiatura i mysz — wymagają sprawności ruchowej, której nie posiadają osoby dotknięte chorobami neurologicznymi takimi jak stwardnienie zanikowe boczne, porażenie czterokończynowe czy zespół zamknięcia. Dla tej grupy pacjentów interfejsy mózg-komputer (ang. *Brain-Computer Interface*, BCI) stanowią często jedyną możliwość komunikacji ze światem zewnętrznym i samodzielnego sterowania urządzeniami. Rosnące zainteresowanie tą technologią, postęp w miniaturyzacji sprzętu EEG oraz dostępność bibliotek do przetwarzania sygnałów biomedycznych sprawiają, że budowa funkcjonalnego systemu BCI stała się możliwa poza środowiskiem czysto laboratoryjnym.

Spośród paradygmatów stosowanych w systemach BCI, wzrokowe potencjały wywołane stanu ustalonego (ang. *Steady-State Visual Evoked Potentials*, SSVEP) wyróżniają się wysoką skutecznością klasyfikacji, krótkim czasem uczenia się przez użytkownika oraz brakiem konieczności indywidualnej kalibracji klasyfikatora. Zjawisko to polega na synchronizacji aktywności neuronów kory wzrokowej z rytmem migającego bodźca wizualnego, co generuje charakterystyczne prążki w widmie sygnału EEG. Umożliwia to jednoznaczne powiązanie intencji użytkownika z konkretną komendą sterującą na podstawie samego skupienia wzroku.

Niniejsza praca podejmuje problem zaprojektowania i implementacji interfejsu SSVEP umożliwiającego sterowanie kursorem myszy w czasie rzeczywistym przy użyciu ogólnodostępnego sprzętu EEG. Celem pracy jest zbudowanie działającego systemu BCI opartego na płytce OpenBCI Cyton, weryfikacja jego skuteczności w badaniu z udziałem użytkowników oraz ocena użyteczności interfejsu. Przyjęto tezę, że system oparty na analizie korelacji kanonicznej (CCA) jest w stanie poprawnie klasyfikować komendy sterujące u większości użytkowników bez przeprowadzania indywidualnej sesji treningowej.

Cel został osiągnięty poprzez kolejne etapy: analizę literatury dotyczącej metod przetwarzania sygnału SSVEP, projekt architektury wieloprosesowej systemu, implementację modułów akwizycji, filtracji, klasyfikacji i stymulacji wizualnej, a następnie przeprowadzenie badania z trzema uczestnikami obejmującego zadanie sterowania kursorem oraz ocenę skuteczności klasyfikacji komend.

Praca składa się z czterech rozdziałów. Rozdział pierwszy wprowadza pojęcie interfejsu mózg-komputer, omawia metody rejestracji aktywności mózgu ze szczególnym uwzględnieniem elektroencefalografii oraz opisuje rytmy EEG stanowiące podstawę działania systemów BCI. Rozdział drugi przedstawia zjawisko SSVEP, strukturę interfejsu opartego na tym paradygmacie, metody prezentacji bodźców wizualnych oraz algorytmy

przetwarzania sygnału — analizę widmową i analizę korelacji kanonicznej. Rozdział trzeci zawiera opis projektu i implementacji systemu: założenia projektowe, architekturę modułową, dobór częstotliwości stymulacji, implementację klasyfikatora CCA oraz mechanizm bufora decyzyjnego. Rozdział czwarty przedstawia wyniki badania przeprowadzonego z udziałem trzech uczestników wraz z omówieniem uzyskanych wyników i wnioskami dotyczącymi dalszego rozwoju systemu.

1. Interfejs mózg–komputer

Od najdawniejszych czasów człowiek starał się poszerzać swoje możliwości poznawcze i praktyczne za pomocą narzędzi. Pierwsze z nich — jak liczydła czy kamienne tablice — służyły do wspomagania podstawowych operacji arytmetycznych. Z biegiem stuleci te proste urządzenia przekształciły się w coraz bardziej złożone maszyny obliczeniowe, aż po koncepcje maszyn programowalnych. U podstaw tego rozwoju leżała nie tylko potrzeba zwiększenia mocy obliczeniowej, lecz także dążenie do uproszczenia komunikacji między człowiekiem a narzędziem.

Za prekursora tej idei uważa się Charlesa Babbage’a, który w XIX wieku zaprojektował maszynę analityczną — pierwszą koncepcję programowalnego komputera [1]. W jego projekcie dane oraz instrukcje miały być wprowadzane za pomocą kart perforowanych, a wyniki — drukowane lub zapisywane na kartach perforowanych w celu możliwości dalszego przetwarzania. Choć maszyna Babbage’a nigdy nie została w pełni zrealizowana, wyznaczyła kierunek dla późniejszego rozwoju informatyki: automatyzacji przetwarzania informacji oraz poszukiwania sposobów na bardziej bezpośrednią interakcję z maszyną. Pierwsze komputery XX wieku były urządzeniami zarezerwowanymi dla specjalistów. Programowanie wymagało manualnego łączenia przewodów i ustawiania przełączników. Podstawową barierą komunikacyjną stanowiła różnica między symbolicznym językiem człowieka a binarną reprezentacją danych w komputerze. Każda interakcja była czasochłonna i obca ludzkiej intuicji. W drugiej połowie lat 50. XX wieku pojawiły się pierwsze próby połączenia komputerów z maszynami do pisania. Jednym z pionierskich rozwiązań był IBM 610, który jako jeden z pierwszych komputerów wykorzystywał klawiaturę do wprowadzania danych [1]. W połączeniu z interfejsem tekstowym, doprowadziło to do popularyzacji klawiatur jako urządzeń wejściowych oraz rozwoju języków programowania.

W miarę jak komputery stawały się coraz bardziej dostępne, wzrastało zapotrzebowanie na bardziej intuicyjne sposoby interakcji z nimi. Klawiatura i interfejs tekstowy umożliwiły użytkownikowi komunikację za pomocą języka pisanego, lecz wciąż była to forma symboliczna, daleka od naturalnych działań człowieka w świecie fizycznym. Przełom nastąpił w latach 60., kiedy amerykański badacz Douglas Engelbart opracował w Stanford Research Institute pierwszy prototyp myszy komputerowej [15]. Urządzenie wykonane z drewna, wyposażone w dwa metalowe kółka, pozwalało użytkownikowi wskazywać i manipulować obiektami na ekranie w sposób przypominający ruch ręki po powierzchni stołu. W 1968 roku Engelbart zaprezentował swój wynalazek podczas słynnej prezentacji „The Mother of All Demos”, w której po raz pierwszy pokazano także działające okna, hiperłącza i współpracę online w czasie rzeczywistym. Demonstracja ta stała się punktem zwrotnym w historii interfejsów użytkownika, wyznaczając kierunek rozwoju ku środo-

wiskom graficznym. Idea Engelbarta, rozwinięta później przez ośrodki badawcze Xerox PARC [34] i komercyjnie wdrożona przez firmę Apple w latach 80., doprowadziła do powstania współczesnych interfejsów graficznych (GUI). Od tamtego momentu zamiast tylko wydawać abstrakcyjne polecenia w terminalu człowiek mógł również manipulować obiektami na ekranie.

1.1 Komunikacja z komputerem w dzisiejszych czasach

Współczesny świat zdominowany jest przez urządzenia komputerowe, które stały się nieodłącznym elementem codziennego życia. Przełomowym momentem w rozwoju technologii interakcji człowieka z maszyną był rok 2007, kiedy firma Apple zaprezentowała iPhone'a — pierwszy smartfon w pełni oparty na ekranie dotykowym [2]. Choć sama idea dotykowej obsługi urządzeń nie była nowa, to właśnie w tym okresie rozpoczęła się jej masowa popularyzacja. Już wcześniej ekrany dotykowe znajdowały zastosowanie w terminalach, bankomatach i specjalistycznych panelach sterujących, jednak dopiero rozwój elektroniki użytkowej uczynił je standardem. Warto dodać, że początki technologii ekranów dotykowych sięgają lat sześćdziesiątych XX wieku [24].

W konstrukcji ekranów dotykowych stosuje się kilka odmiennych zasad działania. Najstarsze z nich wykorzystywały zjawisko zmiany oporu elektrycznego pomiędzy przezroczystymi warstwami przewodzącymi. Rozwiązania tego typu, nazywane ekranami rezystancyjnymi, pozwalały na obsługę przy użyciu dowolnego przedmiotu, w tym rysika, lecz cechowały się mniejszą precyzją i niższą odpornością mechaniczną. W późniejszych latach opracowano technologie oparte na przerwaniu wiązki podczerwieni emitowanej przez diody rozmieszczone na krawędziach ekranu oraz na zaburzeniu fali akustycznej rozchodzącej się po jego powierzchni (technologia *Surface Acoustic Wave*, SAW). Technologia detekcji w podczerwieni znalazła zastosowanie nie tylko w ekranach dotykowych, ale również w innych interfejsach użytkownika, takich jak kontroler ruchu konsoli Nintendo Wii. W tym rozwiązaniu optyczny czujnik w pilocie odczytywał pozycję dwóch diod podczerwonych w tzw. sensor barze, a dane z czujników inercyjnych (akcelerometrów i żyroskopu) umożliwiały precyzyjne odwzorowanie ruchu w trzech wymiarach. Największą popularność zdobyły jednak ekrany pojemnościowe, które działają na zasadzie zmiany pola elektrostatycznego w miejscu kontaktu z przewodzącym materiałem, takim jak ludzka skóra. Umożliwiają one precyzyjną i płynną obsługę, a także wykrywanie wielu punktów dotyku jednocześnie (funkcja *multi-touch*). Ich podstawową wadą jest brak reakcji na przedmioty nieprzewodzące prądu, co uniemożliwia obsługę w rękawiczkach lub za pomocą tradycyjnego rysika. Pomimo wyższych kosztów produkcji, technologia pojemnościowa niemal całkowicie zastąpiła wcześniejsze rozwiązania i obecnie stanowi standard w smartfonach, tabletach oraz panelach sterujących.

Kolejnym etapem rozwoju metod interakcji człowieka z komputerem stały się interfejsy bezdotykowe, wykorzystujące rozpoznawanie gestów, mowy, ruchu ciała lub kierunku spojrzenia użytkownika. Rozwiązania tego typu umożliwiają komunikację z urządzeniem bez fizycznego kontaktu, co znacząco zwiększa intuicyjność obsługi i poszerza zakres możliwych zastosowań. Przykładem takiej technologii jest system Microsoft Kinect, który po raz pierwszy został zaprezentowany w 2010 roku jako urządzenie peryferyjne dla konsoli Xbox 360. System ten wykorzystywał zestaw kamer, czujników głębi oraz mikrofonów

do analizy pozycji ciała, gestów i poleceń głosowych użytkownika w czasie rzeczywistym. Dzięki temu możliwe było sterowanie gram i aplikacjami za pomocą ruchu rąk, tułowia czy komend głosowych, bez konieczności używania tradycyjnego kontrolera. Wprowadzenie technologii głębi 3D umożliwiło również śledzenie przestrzenne wielu użytkowników jednocześnie, co stanowiło istotny krok w kierunku bardziej naturalnej interakcji z systemami komputerowymi.

Najbardziej naturalną formą komunikacji człowieka z otoczeniem jest mowa, dlatego też próby jej wykorzystania jako środka sterowania komputerem rozpoczęto już w latach pięćdziesiątych XX wieku. W 1952 roku K. H. Davis, R. Biddulph i S. Balashek opracowali pierwszy system zdolny do rozpoznawania wypowiedzianych cyfr [12]. W kolejnych dekadach rozwój tej technologii koncentrował się na systemach ograniczonych słownikowo lub dostosowanych do konkretnego użytkownika, co pozwalało zwiększyć dokładność rozpoznawania w warunkach ograniczonej mocy obliczeniowej. Rozpoznawanie mowy jest zagadnieniem złożonym, ponieważ wymaga analizy sygnału akustycznego oraz jego interpretacji językowej. Zmienność głosu, akcentu, tempa mówienia czy obecność zakłóceń sprawiają, że stworzenie uniwersalnego systemu zdolnego do rozumienia mowy potocznej stanowi duże wyzwanie. Współczesne rozwiązania wykorzystują jednak zaawansowane modele akustyczne i językowe oparte na sztucznych sieciach neuronowych, co pozwoliło znacząco zwiększyć dokładność i naturalność interakcji głosowej.

Technologie rozpoznawania mowy znajdują zastosowanie przede wszystkim w sterowaniu urządzeniami oraz w transkrypcji tekstu mówionego. Coraz częściej pełnią także rolę narzędzia komunikacji, umożliwiając porozumiewanie się osób mówiących w różnych językach w czasie rzeczywistym. Powszechne stały się systemy asystentów głosowych, takich jak Siri, Alexa czy Google Assistant, które pozwalają wykonywać polecenia, wyszukiwać informacje i sterować inteligentnymi urządzeniami domowymi przy użyciu komend słownych. Rozwiązania te stanowią ważny krok w kierunku bardziej naturalnej komunikacji z komputerem, przybliżając ją do sposobu, w jaki ludzie porozumiewają się ze sobą.

W idealnym świecie człowiek nie musiałby wydawać poleceń komputerowi — maszyna sama wiedziałaby, co chcemy osiągnąć, jakby czytała nasze myśli. Choć wizja ta pozostaje w sferze *science fiction*, jej częściowe realizacje istnieją już w świecie rzeczywistym. Obecnie największym ograniczeniem interfejsów BCI jest stosunkowo niska szybkość komunikacji. Mimo to systemy te znalazły zastosowanie w psychologii, technikach multimedialnych, wojskowości, a przede wszystkim w medycynie. Tam stanowią często jedyny sposób komunikacji ze światem zewnętrznym dla osób dotkniętych poważnymi chorobami neurologicznymi — takimi jak stwardnienie zanikowe boczne, udary mózgu czy urazy rdzenia kręgowego — które stopniowo ograniczają kontrolę nad ruchem ciała. W takich przypadkach interfejs mózg–komputer pozwala nie tylko na podstawową komunikację, ale również na sterowanie protezami, wózkiem inwalidzkim czy inteligentnym domem.

1.2 Zastosowania interfejsów mózg–komputer

Interfejsy mózg–komputer znajdują zastosowanie w wielu dziedzinach. Ich rozwój koncentruje się głównie na umożliwieniu osobom z niepełnosprawnościami komunikacji oraz

kontroli urządzeń. W medycynie systemy BCI są wykorzystywane do przywracania funkcji ruchowych u pacjentów z paraliżem, umożliwiając sterowanie protezami kończyn lub wózkami inwalidzkimi za pomocą myśli [21]. Ponadto BCI jest wykorzystywane w celu wspomagania komunikacji osób z zespołem zamknięcia (*locked-in syndrome*), które nie mogą poruszać się ani mówić. Dzięki analizie sygnałów EEG możliwe jest rozpoznawanie intencji ruchu, co pozwala na wykonywanie prostych czynności, takich jak poruszanie kursorem lub wybór znaków na wirtualnej klawiaturze.


Jednym z wielu obszarów zastosowań jest neurorehabilitacja, gdzie BCI wspomagają procesy odzyskiwania funkcji motorycznych po udarach mózgu lub urazach rdzenia kręgowego. Systemy te wykorzystują neuroplastyczność mózgu, umożliwiając pacjentom ćwiczenie kontrolowanych ruchów poprzez wizualizację i sprzężenie zwrotne [13]. W praktyce BCI często integruje się z egzoszkieletami lub systemami funkcjonalnej stymulacji elektrycznej (FES), co pozwala na bezpośrednie wspomaganie wykonywanych ruchów. Badania kliniczne potwierdzają skuteczność takiego podejścia — w badaniu Frolova i in. zastosowanie egzoszkieletu sterowanego poprzez wyobrażenie ruchu doprowadziło do istotnej poprawy funkcji ręki u pacjentów po udarze w porównaniu z grupą kontrolną [17]. Podobne wyniki uzyskano w eksperymencie Bundy’ego i współpracowników, gdzie uczestnicy sterowali egzoszkieletem kończyny górnej za pomocą sygnałów EEG z nieuszkodzonej półkuli, co przełożyło się na wzrost aktywności korowej i poprawę wyników testów motorycznych [9]. Takie zamknięte pętle treningowe mogą zwiększać aktywność korową i przyspieszać odzyskiwanie kontroli motorycznej, szczególnie przy intensywnym i spersonalizowanym treningu. Efektywność terapii zależy jednak od stopnia uszkodzenia, czasu od urazu oraz dopasowania protokołu rehabilitacyjnego.

Coraz większe znaczenie zyskują także zastosowania poznawcze i badawcze, obejmujące analizę uwagi, zmęczenia czy emocji użytkownika. W takich przypadkach BCI służy do oceny stanu psychofizjologicznego w czasie rzeczywistym, co może być użyteczne np. w transporcie, wojsku lub podczas złożonych zadań wymagających wysokiej koncentracji.

1.3 Struktura interfejsu mózg–komputer

Podstawowa struktura interfejsu mózg–komputer (BCI) została opracowana w latach 70. XX wieku wraz z pracami Jacquesa Vidala, który wprowadził pojęcie BCI i przeprowadził pierwsze eksperymenty umożliwiające sterowanie kursorem lub robotem przy użyciu sygnałów EEG [43, 44]. System BCI składa się z kilku kluczowych etapów przetwarzania sygnału. Pierwszym jest rejestracja aktywności mózgu, najczęściej przy użyciu EEG. Zarejestrowane sygnały wymagają wstępnego oczyszczenia — filtracji zakłóceń fizjologicznych i technicznych — oraz ekstrakcji cech, czyli wyodrębnienia parametrów najbardziej istotnych do interpretacji intencji użytkownika. W tym celu stosuje się filtry dolno- i górno- przepustowe oraz filtry pasmopasmo. Kolejnym krokiem jest klasyfikacja tych cech przy użyciu algorytmów uczenia maszynowego, które pozwala na przypisanie im określonych komend lub decyzji. Ostatni moduł systemu tłumaczy sygnały mózgowe na konkretne działania, takie jak ruch kursora, sterowanie protezą czy wózkiem inwalidzkim. Na rysunku 1.1 przedstawiono schemat działania interfejsu mózg–komputer. Centralnym elementem całego systemu pozostaje komputer, który analizuje, klasyfikuje sygnały oraz generuje sprzężenie zwrotne, tworząc zamkniętą pętlę komunikacyjną między mózgiem a

urządzeniem wykonawczym [3, 47].



Rysunek 1.1: Schemat struktury interfejsu mózg–komputer (Źródło: opracowanie własne na podstawie [25])

1.4 Metody badania aktywności mózgu

Aby interfejs mózg–komputer mógł działać, niezbędne jest poznanie i rejestracja aktywności elektrycznej mózgu. Istnieje wiele technik badania pracy mózgu, różniących się stopniem inwazyjności, dokładnością i zastosowaniami [20, 37]. Metody inwazyjne obejmują implantowane elektrody domózgowe (IntraCortical Recordings, IR), które pozwalają na bezpośrednie odczytywanie sygnałów neuronów z bardzo wysoką rozdzielczością czasową i przestrzenną. Ich zastosowanie ogranicza jednak wysoki stopień ingerencji chirurgicznej i związane z tym ryzyko. Metody częściowo inwazyjne, takie jak elektrokortykografia (Electrocorticography, ECoG), wykorzystują elektrody umieszczane na powierzchni kory mózgowej. Dają one lepszą jakość sygnału niż metody nieinwazyjne, przy mniejszym ryzyku niż pełne implanty. Metody nieinwazyjne nie wymagają ingerencji chirurgicznej i są bezpieczne do wielokrotnych pomiarów u zdrowych osób. Należą do nich:

- Magnetoencefalografia (MEG) — rejestruje pola magnetyczne generowane przez aktywność neuronów.
- Funkcjonalny rezonans magnetyczny (fMRI) — mierzy zmiany przepływu krwi w mózgu jako wskaźnik aktywności neuronów.
- Tomografia optyczna (NIRS) — wykorzystuje bliską podczerwień do pomiaru przepływu krwi i saturacji tlenu w tkankach mózgowych.
- Pozytonowa tomografia emisyjna (PET) — pozwala śledzić metabolizm i przepływ krwi.

- Elektroencefalografia (EEG) — rejestruje elektryczną aktywność mózgu za pomocą elektrod umieszczonych na skórze głowy.

Choć istnieje kilka metod nieinwazyjnego badania aktywności mózgu, tylko niektóre nadają się do zastosowania w systemach BCI codziennego użytku. Techniki takie jak MEG, PET, fMRI czy tomografia optyczna oferują precyzyjną lokalizację aktywnych obszarów mózgu, jednak są kosztowne, wymagają skomplikowanego sprzętu i specjalistycznej obsługi. Co więcej, mierzą pośrednie efekty aktywności neuronów, takie jak zmiany przepływu krwi, które zachodzą znacznie wolniej niż rzeczywiste impulsy nerwowe, ograniczając szybkość interakcji. Elektroencefalografia za to, przeciwnie, pozwala rejestrować aktywność mózgu w czasie rzeczywistym, jest stosunkowo tania i łatwa w użyciu. Dzięki temu systemy BCI oparte na EEG mogą działać w różnych warunkach, a po krótkim przeszkoleniu użytkownika — nawet w domu. To czyni EEG najbardziej praktycznym wyborem do interfejsów mózg–komputer.


Sygnał EEG odzwierciedla zbiorową aktywność dużych grup neuronów, co sprawia, że pomiar jest obciążony naturalnymi ograniczeniami dokładności. W odróżnieniu od pomiarów technicznych, gdzie obserwowany parametr istnieje wprost, w biologii sam obiekt pomiaru bywa mniej jednoznaczny. Z tego powodu pojedyncza rejestracja EEG rzadko dostarcza pełnej informacji, a wiarygodne wyniki wymagają wielokrotnych powtórzeń i zastosowania analizy statystycznej. Pomimo tych ograniczeń, sygnał EEG dostarcza cennych danych o stanie funkcjonalnym mózgu. Analiza jego struktury czasowo–częstotliwościowej pozwala wyróżnić charakterystyczne wzorce aktywności neuronalnej, zwane rytmami EEG, które stanowią podstawę interpretacji i wykorzystania sygnału w systemach BCI.

1.5 Pomiar sygnału EEG

Do rejestracji sygnału EEG stosuje się zestaw elektrod przytwierdzanych do skóry głowy, zazwyczaj z użyciem przewodzącego żelu. Elektrody te wychwytyują aktywność elektryczną mózgu, która następnie jest wzmacniana i przetwarzana w formę cyfrową przez elektroencefalograf. Urządzenie to mierzy różnice potencjałów między elektrodami umieszczonymi na głowie. Sygnały te są bardzo słabe — ich amplituda nie przekracza kilkudziesięciu μV — dlatego niezbędne jest zastosowanie wzmacniaczy. Po wzmocnieniu sygnał jest próbkowany i zapisywany w postaci cyfrowej, co umożliwia jego dalszą analizę.

Rozmieszczenie elektrod na głowie odbywa się według tzw. międzynarodowego systemu 10–20, opracowanego przez Herberta Jaspera w 1958 roku. System ten określa pozycje elektrod w oparciu o odległości pomiędzy charakterystycznymi punktami anatomicznymi czaszki: nasadą nosa (*nasion*), guzowatością potyliczną (*inion*) oraz punktami przeduszno–skroniowymi [22]. Odległości między sąsiednimi elektrodami stanowią odpowiednio 10% lub 20% całkowitej długości wybranego wymiaru głowy, co zapewnia powtarzalność i porównywalność pomiarów między badaniami. Każda elektroda oznaczona jest literą odpowiadającą regionowi mózgu, nad którym się znajduje (F — czołowy, C — centralny, P — ciemieniowy, O — potyliczny, T — skroniowy) oraz cyfrą: nieparzyste numery odnoszą się do lewej półkuli, a parzyste do prawej. Punkt środkowy oznacza się literą „Z” (od ang. *zero line*), np. Fz lub Cz. W praktyce standardowy zestaw EEG obejmuje od 19 do 21 elektrod, jednak w badaniach naukowych często stosuje się systemy

o większej gęstości (np. 10–10 lub 10–5), zawierające nawet kilkaset elektrod, co pozwala na dokładniejsze odwzorowanie przestrzennego rozkładu aktywności mózgu. Na rysunku 1.2 przedstawiono schemat rozmieszczenia elektrod w standardowym systemie 10–20.



Rysunek 1.2: Rozmieszczenie elektrod na powierzchni głowy w standardowym systemie 10–20 stosowanym w elektroencefalografii

Elektrody EEG mogą być wykonane z różnych materiałów przewodzących, takich jak srebro, chlorek srebra (Ag/AgCl) czy złoto. Najczęściej stosuje się elektrody Ag/AgCl ze względu na ich stabilność potencjału i odporność na dryft napięcia. W zależności od sposobu montażu wyróżnia się elektrody przyklejane, żelowe, suche oraz półsuche. Elektrody suche eliminują konieczność użycia żelu przewodzącego, co zwiększa wygodę użytkownika, ale często wiąże się z większym szumem kontaktowym i mniejszą jakością rejestracji.

Typowy system EEG obejmuje również elektrodę odniesienia (*reference electrode*) oraz elektrodę uziemiającą (*ground electrode*). Elektroda odniesienia stanowi punkt odniesienia potencjałów mierzonych przez pozostałe elektrody i może być umieszczona np. na małżowinie usznej lub w punkcie Cz. Sposób wyboru elektrody odniesienia ma istotny wpływ na kształt i interpretację zarejestrowanego sygnału, dlatego w analizie EEG często stosuje się techniki przeliczeniowe, np. odniesienie wspólne lub tzw. *average reference*, w którym od każdego kanału odejmuje się średnią wartość sygnałów ze wszystkich elektrod. Współczesne elektroencefalografy umożliwiają rejestrację wielu kanałów jednocześnie (od 8 do nawet 256), a także integrację z innymi systemami pomiarowymi, np. śledzenia wzroku, EMG czy EKG. Urządzenia te coraz częściej wykorzystują technologie bezprzewodowe, co zwiększa mobilność i umożliwia prowadzenie pomiarów poza laboratorium. Dzięki postępowi w miniaturyzacji elektroniki, przenośne zestawy EEG stają się coraz powszechniejsze również w zastosowaniach domowych, edukacyjnych i rozrywkowych.

1.6 Rytm EEG

Rejestrowany sygnał EEG ma bardzo małą amplitudę — zwykle od kilku do kilkudziesięciu μV i jest silnie narażony na zakłócenia. Źródłem szumów mogą być zarówno czynniki zewnętrzne, jak zakłócenia sieciowe o częstotliwości 50 Hz (lub 60 Hz) czy urządzenia elektryczne w otoczeniu, jak i wewnętrzne, takie jak ruchy mięśni twarzy, napięcie mięśni

czoła, ruchy gałek ocznych czy sygnały z serca. W praktyce zakłócenia te często osiągają amplitudy wielokrotnie większe niż właściwy sygnał mózgowy, co wymaga stosowania zaawansowanych metod filtracji i przetwarzania. Mimo to, analiza EEG pozwala na identyfikację charakterystycznych wzorców aktywności mózgu, zwanych rytmami lub falami. Są to sygnały o względnie regularnej strukturze i określonym zakresie częstotliwości, które odzwierciedlają stan funkcjonalny mózgu. Wyróżnia się pięć głównych rytmów: delta, theta, alfa, beta i gamma. Ich parametry mogą się różnić w zależności od wieku, stanu psychicznego oraz fizjologicznego badanego. Na rysunku 1.3 przedstawiono przykładowe sygnały poszczególnych rytmów EEG.

Rytm delta (0,5–4 Hz)

Rytmy delta występują w najniższym zakresie częstotliwości. Są charakterystyczne dla snu głębokiego i stanów utraty świadomości. U dorosłych pojawienie się fal delta w stanie czuwania może wskazywać na nieprawidłowości w funkcjonowaniu ośrodkowego układu nerwowego. W zapisie EEG dzieci rytmy delta są jednak zjawiskiem fizjologicznym. Typowa amplituda fal delta wynosi około $50 \mu\text{V}$, a ich obecność obserwuje się zwykle na obszarze czołowo–centralnym i w stanie relaksu lub snu.

Rytm theta (4–7 Hz)

Rytmy theta wiążą się z obniżonym poziomem czuwania, sennością, marzeniami sennymi oraz wczesnymi fazami snu. Występują także podczas stanów głębokiego relaksu, medytacji czy chwilowego oderwania uwagi od bodźców zewnętrznych. U dorosłych duży udział fal theta w stanie aktywnego czuwania może wskazywać na zaburzenia neurologiczne lub nadmierne zmęczenie. Amplituda tego rytmu nie przekracza zazwyczaj $30 \mu\text{V}$. W zapisie EEG fale theta pojawiają się głównie w odprowadzeniach środkowych.

Rytm alfa (8–13 Hz)


Rytmy alfa zostały opisane po raz pierwszy przez Hansa Bergera w 1930 roku i są uznawane za podstawowy wzorec aktywności mózgu u dorosłych. Występują głównie w stanie spoczynku, przy zamkniętych oczach i braku intensywnego skupienia. Zanik rytmu alfa następuje po otwarciu oczu lub w sytuacji silnego pobudzenia psychicznego. Sygnał ten jest najlepiej widoczny w okolicach potylicznych, czyli nad korą wzrokową. Częstotliwość rytmu alfa mieści się w przedziale 8–13 Hz, a amplituda wynosi zwykle $20\text{--}100 \mu\text{V}$. Całkowity brak tego rytmu u osoby dorosłej w stanie relaksu może wskazywać na zaburzenia neurologiczne.

Rytm beta (13–30 Hz)

Rytmy beta obejmują fale o wyższych częstotliwościach i mniejszej amplitudzie, które dominują podczas aktywności umysłowej, koncentracji, analizy informacji oraz w trakcie ruchu. Występują głównie w przednich częściach mózgu, szczególnie w rejonach czołowo–centralnych. Rytm beta wykazuje znaczną zmienność amplitudy, co ogranicza jego zastosowanie diagnostyczne. Obserwuje się także asymetrię międzypółkulową, która może mieć znaczenie kliniczne — np. słabsza obecność rytmu beta w jednej półkuli bywa powiązana z zaburzeniami funkcjonalnymi. Część leków, zwłaszcza barbiturany, zwiększa amplitudę i udział fal beta w zapisie EEG.

Rytm gamma (30–70 Hz)

Fale gamma występują w najwyższym zakresie częstotliwości i wiązane są z procesami poznawczymi wyższego rzędu: percepcją, zapamiętywaniem, integracją informacji sensorycznych oraz aktywnością ruchową. Aktywność gamma odzwierciedla szybkie procesy synchronizacji między różnymi obszarami mózgu i jest uznawana za wskaźnik intensywnego przetwarzania informacji. Choć fale te mają niewielką amplitudę, ich analiza dostarcza cennych danych o mechanizmach świadomości i uwagi.



Rysunek 1.3: Próbkki sygnałów poszczególnych rytmów EEG [51]

2. Interfejs korzystający z wzrokowych potencjałów wywołanych stanu ustalonego

2.1 Wzrokowe potencjały wywołane stanu ustalonego (SSVEP)


Wzrokowe potencjały wywołane stymulacją o stałej częstotliwości (ang. *Steady-State Visual Evoked Potentials*, SSVEP) są jednym z najbardziej rozpowszechnionych i skutecznych zjawisk wykorzystywanych w systemach BCI [35, 42]. Zjawisko to opiera się na obserwacji bodźców wizualnych migających z określoną częstotliwością. Kiedy użytkownik skupia wzrok na danym bodźcu, w obszarze kory wzrokowej — głównie w okolicach potylicznych — pojawia się rytmiczna aktywność o tej samej częstotliwości, co częstotliwość migotania bodźca, oraz jej wielokrotności [16, 47]. Odpowiedź tę łatwo wykryć w zapisie EEG; cechuje się wysoką powtarzalnością między osobami badanymi. Fizjologiczną podstawą powstawania potencjałów SSVEP jest rezonansowa odpowiedź neuronów kory wzrokowej na rytmiczną stymulację [38, 40].

W typowych systemach BCI opartych na SSVEP stosuje się kilka lub kilkanaście bodźców wizualnych, z których każdy migocze z inną częstotliwością [7, 33]. Użytkownik dokonuje wyboru, skupiając wzrok na wybranym bodźcu, a system analizuje zapis EEG, identyfikując dominującą częstotliwość sygnału. Dużą zaletą SSVEP jest stosunkowo wysoki stosunek sygnału do szumu (SNR) oraz niewielkie wymagania treningowe — użytkownik nie musi opanowywać skomplikowanych strategii mentalnych, jak w przypadku potencjałów ruchowych. Systemy oparte na SSVEP osiągają bardzo wysoką dokładność klasyfikacji (nawet powyżej 95%) i krótki czas reakcji [35]. Należy jednak zauważyć, że metody SSVEP mają również ograniczenia. Wymagają stałej stymulacji wizualnej, co przy dłuższym użytkowaniu może prowadzić do zmęczenia wzroku lub dyskomfortu. Ponadto skuteczność systemu zależy od indywidualnych różnic w czułości na bodźce migające — nie u wszystkich użytkowników uzyskuje się równie silne odpowiedzi [16, 42].

2.2 Struktura interfejsu SSVEP

Interfejs SSVEP składa się z kilku współpracujących modułów, które wspólnie umożliwiają detekcję i interpretację odpowiedzi wzrokowej użytkownika [38]. Pierwszym z nich jest moduł stymulatora, odpowiedzialny za generowanie bodźców wizualnych o określonej częstotliwości i właściwościach fizycznych, takich jak barwa, jasność i kontrast [23, 46]. Kolejnym elementem jest system akwizycji EEG, obejmujący elektrody, wzmacniacze

oraz wstępne filtry, które umożliwiają rejestrację sygnałów elektrycznych generowanych przez korę wzrokową [47]. Zarejestrowany sygnał trafia następnie do modułu przetwarzania i analizy, w którym stosuje się metody ekstrakcji cech częstotliwościowych — omówione szczegółowo w sekcji 2.5 — w celu wyodrębnienia komponentów odpowiadających konkretnym bodźcom wizualnym [7, 35]. Wyniki analizy interpretuje moduł klasyfikacji, który identyfikuje bodziec będący obiektem uwagi użytkownika i przekazuje odpowiednią komendę do systemu sterowania lub interfejsu użytkownika [18]. Całość działania wspiera interfejs wizualny lub sterujący, reagujący na wybór użytkownika w czasie rzeczywistym, umożliwiając np. wybór liter, sterowanie obiektami w środowisku wirtualnym lub kontrolę urządzeń zewnętrznych [11, 26]. Funkcjonalny model takiego rozwiązania przedstawiono na rysunku 2.1.




Rysunek 2.1: Funkcjonalny model interfejsu BCI opartego na SSVEP. Opracowanie własne na podstawie: [6].

2.3 Sposoby prezentacji bodźców

Tradycyjnie bodźce w eksperymentach SSVEP prezentuje się na monitorach komputerowych. Precyzyjna kontrola częstotliwości migotania bodźców jest kluczowa, ponieważ odpowiedź EEG uczestnika jest silnie zsynchronizowana z tą częstotliwością. Niedokładna synchronizacja może prowadzić do zniekształceń sygnału i spadku skuteczności detekcji. Starsze ekrany kineskopowe (CRT) umożliwiały bardzo precyzyjną kontrolę częstotliwości odświeżania, sięgającą nawet 160 Hz, w zależności od rozdzielczości i trybu pracy [49]. Pomimo tej zalety, monitory CRT nie są obecnie praktycznym wyborem ze względu na duże rozmiary, masę oraz wysokie zużycie energii.

Współczesne monitory LCD osiągają porównywalne lub wyższe częstotliwości odświeżania przy lepszej rozdzielczości i niższym zapotrzebowaniu energetycznym [45, 48]. Typowy monitor LCD o częstotliwości odświeżania 60 Hz pozwala generować bodźce o częstotliwościach będących dzielnikami tej wartości, np. w zakresie 10–30 Hz. Nowoczesne wyświetlacze z odświeżaniem 120–240 Hz umożliwiają szerszy zakres częstotliwości

i gęstsze rozmieszczenie bodźców bez ryzyka nakładania się odpowiedzi SSVEP z różnych źródeł [23, 41]. Przykładowy sposób użycia monitora LCD w interfejsie SSVEP zaprezentowano na rysunku 2.2. Monitory LCD mają jednak ograniczenia wynikające z fizycznych właściwości wyświetlaczy. Czas reakcji pikseli rzędu kilku milisekund może powodować niewielkie opóźnienia w migotaniu bodźców, a przy dużej liczbie bodźców na ekranie możliwe jest nakładanie się odpowiedzi SSVEP w sygnale EEG. Dlatego w eksperymentach SSVEP nie zaleca się używania ekranów, których czas reakcji zwykle przekracza 5 ms. Synchronizacja prezentacji bodźców z klatkami monitora jest dokładniejsza niż korzystanie z timerów systemowych, które mogą powodować niewielkie wahania czasowe. Badania wykazują, że synchronizacja z odświeżaniem monitora pozwala osiągnąć skuteczność generowania bodźców na poziomie około 90%. Dodatkowo stosowanie metod niesymetrycznych lub przesunięcia fazowego umożliwia generowanie częstotliwości pośrednich, zwiększając liczbę dostępnych komend w interfejsach BCI bez konieczności zmiany sprzętu [23, 41].



Rysunek 2.2: Przykładowe użycie monitora LCD jako źródła bodźców w eksperymencie SSVEP. Źródło: [8].

Oprócz monitorów LCD, w literaturze szeroko analizowano wpływ rodzaju źródła światła na jakość rejestrowanych potencjałów SSVEP. W szczególności panele z diodami LED wykazują znacznie lepsze właściwości stymulacyjne w porównaniu z wyświetlaczami LCD i CRT [46]. Diody LED charakteryzują się bardzo krótkim czasem reakcji (rzędu mikrosekund), co umożliwia generowanie migotania o niemal dowolnej częstotliwości bez widocznych opóźnień czy nieliniowości. Dzięki temu bodźce są wyświetlane z wysoką precyzją fazową i minimalnym rozmyciem luminancji, co skutkuje większą stabilnością oraz amplitudą rejestrowanych potencjałów [10]. Badania porównawcze wykazały, że stymulacja wzrokowa za pomocą diod LED prowadzi do najwyższych wartości współczynnika SNR oraz amplitudy SSVEP spośród wszystkich testowanych urządzeń [39]. Dla wyższych częstotliwości (15–32 Hz) amplitudy sygnałów generowanych przez panele LED przekraczały dwukrotnie wartości uzyskane dla wyświetlaczy LCD i CRT. Coraz częściej analizuje się również wykorzystanie ekranów OLED w kontekście SSVEP. Wy-

świetlacze te oferują doskonały kontrast oraz szeroki zakres odwzorowania barw, jednak ich czas reakcji pikseli i charakter modulacji luminancji ograniczają skuteczność generowania stabilnych potencjałów [39]. W eksperymentach stwierdzono, że dla częstotliwości 32 Hz bodźce prezentowane za pomocą OLED nie wywoływały mierzałnej odpowiedzi SSVEP.

Na jakość potencjałów SSVEP wpływają nie tylko rodzaj wyświetlacza, lecz także parametry samego bodźca. Szczególnie istotne są barwa, kontrast oraz jasność światła. Wykazano, że bodźce niebieskie i zielone generują silniejsze odpowiedzi SSVEP niż bodźce czerwone, co wynika z większej wrażliwości siatkówki na krótsze długości fal [23, 46]. Z kolei zbyt wysoki kontrast lub nadmierna luminancja mogą prowadzić do szybkiego zmęczenia wzroku i obniżenia komfortu użytkownika.

2.4 Akwizycja sygnałów EEG w interfejsach SSVEP

Do akwizycji sygnałów EEG niezbędny jest wielokanałowy system rejestracji. Liczba elektrod zależy od przyjętej strategii pomiarowej, jednak w typowych systemach SSVEP zaleca się stosowanie od 8 do 32 kanałów, szczególnie w obszarze potylicznym i ciemieniowym (np. O1, O2, Oz, POz, Pz), gdzie amplituda odpowiedzi SSVEP jest największa [35]. Elektrody mogą być mokre (z żelem przewodzącym) lub suche; elektrody mokre oferują wyższy stosunek sygnału do szumu i lepszy kontakt elektryczny, natomiast elektrody suche umożliwiają szybsze przygotowanie pomiaru i większy komfort użytkownika kosztem nieco niższej jakości sygnału [32].

Ważnym aspektem jest synchronizacja między systemem stymulacji wizualnej a systemem rejestracji EEG. Bodźce migają z określoną częstotliwością, a precyzyjna synchronizacja gwarantuje, że zarejestrowane sygnały odpowiadają faktycznym momentom prezentacji bodźca. Do synchronizacji wykorzystuje się różne metody, takie jak detekcja sygnału wyjściowego z monitora (np. fotodioda) lub protokoły komunikacyjne o niskim opóźnieniu w przypadku stymulacji VR/AR [35]. Brak dokładnej synchronizacji skutkuje przesunięciami fazowymi i błędną identyfikacją częstotliwości dominujących. Ostatnim etapem jest zapis danych w odpowiednim formacie z uwzględnieniem metadanych: oznaczenia kanałów, częstotliwości próbkowania, momentu rozpoczęcia i zakończenia pomiaru, parametrów filtrów oraz danych kalibracyjnych. Taki zapis umożliwia późniejsze przetwarzanie, analizę harmoniczną i synchronizację z bodźcami.

2.5 Metody przetwarzania wykorzystane w interfejsie SSVEP

Po akwizycji sygnału EEG następuje jego wstępne przetwarzanie, obejmujące filtrowanie pasmowe oraz usuwanie artefaktów. Filtrowanie pasmowe ogranicza sygnał do interesującego zakresu częstotliwości, redukując zakłócenia niskoczęstotliwościowe oraz szумы wysokoczęstotliwościowe generowane przez mięśnie lub sprzęt [42, 46]. Artefakty ruchowe i zakłócenia sieciowe mogą być dodatkowo tłumione przy użyciu metod takich jak regresja liniowa lub analiza składowych niezależnych (ICA) [29]. Tak przygotowany sygnał trafia do modułu ekstrakcji cech, który identyfikuje komponenty częstotliwościowe odpowiadające konkretnym bodźcom wizualnym.

Przygotowany sygnał EEG dla kanału *c* można zapisać jako:

$$X_c[n] = F(x_c[n]), \quad n = 0, 1, \dots, N-1$$

gdzie $x_c[n]$ to sygnał surowy z kanału c , F oznacza operację filtrowania, a N jest liczbą próbek w analizowanym oknie czasowym.

Analiza w dziedzinie częstotliwości – FFT i SNR

Najprostszym podejściem do detekcji bodźca SSVEP jest analiza widmowa sygnału EEG z pojedynczego kanału. Dyskretna transformata Fouriera (DFT), będąca podstawą szybkiej transformaty Fouriera (FFT), definiowana jest jako:

$$X[k] = \sum_{n=0}^{N-1} x[n] e^{-j2\pi kn/N}, \quad k = 0, 1, \dots, N-1 \quad (2.1)$$

Dla sygnałów rzeczywistych analizuje się tylko lewą połowę widma, tj. $k = 0, 1, \dots, N/2$. Częstotliwość odpowiadającą indeksowi k oblicza się ze wzoru $f_k = kf_s/N$, gdzie f_s oznacza częstotliwość próbkowania. Przykładowo, dla $f_s = 250$ Hz i okna $N = 1000$ próbek rozdzielczość częstotliwościowa wynosi 0,25 Hz.

Na podstawie widmowej gęstości mocy (PSD):

$$\text{PSD}[k] = \frac{1}{N} |X[k]|^2 \quad (2.2)$$

można wyznaczyć stosunek sygnału do szumu (SNR) dla każdej częstotliwości bodźca f_b :

$$\text{SNR}(f_b) = \frac{|X[k_b]|^2}{\frac{1}{M} \sum_{m \in \mathcal{N}} |X[m]|^2} \quad (2.3)$$

gdzie k_b jest indeksem odpowiadającym f_b , $\mathcal{N}$ oznacza zbiór sąsiednich prążków tła spektralnego, a M ich liczbę. Metoda SNR jest prosta i skuteczna w systemach o ograniczonych zasobach obliczeniowych, jednak operuje na sygnale z pojedynczego kanału, przez co nie wykorzystuje przestrzennych zależności między elektrodami [7]. W odpowiedzi na to ograniczenie opracowano metody wielokanałowe, z których najbardziej rozpowszechnioną jest analiza korelacji kanonicznej.

Analiza korelacji kanonicznej (CCA)

Analiza korelacji kanonicznej (ang. *Canonical Correlation Analysis*, CCA) jest metodą statystyczną pozwalającą na wyznaczenie maksymalnej korelacji liniowej między dwoma zestawami zmiennych [28]. W kontekście systemów SSVEP pierwszym zestawem jest wielokanałowy sygnał EEG $\mathbf{X} \in \mathbb{R}^{N \times C}$ (gdzie C to liczba kanałów, a N liczba próbek w oknie), natomiast drugim — macierz sygnałów referencyjnych $\mathbf{Y}_{f_k} \in \mathbb{R}^{N \times 2H}$ generowana dla każdej częstotliwości bodźca f_k [7, 35].

Dla częstotliwości f_k i H harmonicznych macierz referencji przyjmuje postać:

$$\mathbf{Y}_{f_k} = \begin{bmatrix} \sin(2\pi f_k t) \\ \cos(2\pi f_k t) \\ \vdots \\ \sin(2\pi H f_k t) \\ \cos(2\pi H f_k t) \end{bmatrix}^T \quad (2.4)$$

gdzie $t = [0, 1/f_s, 2/f_s, \dots, (N-1)/f_s]$ jest wektorem czasu. Uwzględnienie harmonicznych wynika z faktu, że odpowiedź SSVEP w korze wzrokowej pojawia się nie tylko na częstotliwości podstawowej f_k , lecz również na jej wielokrotnościach $2f_k, 3f_k, \dots$ [42]. Algorytm CCA wyznacza wektory kanoniczne $\mathbf{w}_x$ i $\mathbf{w}_y$ maksymalizujące korelację między rzutami:

$$\rho_{f_k} = \max_{\mathbf{w}_x, \mathbf{w}_y} \frac{\mathbf{w}_x^T \mathbf{X}^T \mathbf{Y}_{f_k} \mathbf{w}_y}{\sqrt{\mathbf{w}_x^T \mathbf{X}^T \mathbf{X} \mathbf{w}_x \cdot \mathbf{w}_y^T \mathbf{Y}_{f_k}^T \mathbf{Y}_{f_k} \mathbf{w}_y}} \quad (2.5)$$

Uzyskany współczynnik korelacji kanonicznej $\rho_{f_k} \in [0, 1]$ odzwierciedla stopień podobieństwa między sygnałem EEG a wzorcem referencyjnym dla częstotliwości f_k . Częstotliwość bodźca identyfikowana jako aktualny cel skupienia wzroku użytkownika wyznaczana jest jako:

$$\hat{f} = \arg \max_{f_k \in \mathcal{F}} \rho_{f_k} \quad (2.6)$$

gdzie $\mathcal{F}$ jest zbiorem wszystkich częstotliwości bodźców. Kluczową zaletą CCA względem metod jednokanałowych jest jednoczesne przetwarzanie sygnałów ze wszystkich elektrod, co pozwala wyznaczyć optymalną kombinację liniową kanałów i tym samym zwiększyć odporność klasyfikatora na szумы oraz artefakty ograniczone przestrzennie [7, 16]. Metoda ta nie wymaga danych treningowych, gdyż sygnały referencyjne są generowane analitycznie na podstawie znajomości częstotliwości bodźców.

2.6 Przykładowe interfejsy SSVEP

Rozwój współczesnych interfejsów SSVEP koncentruje się na redukcji zmęczenia wzrokowego, zwiększeniu komfortu użytkownika oraz integracji z metodami uczenia głębokiego i systemami adaptacyjnymi. Coraz częściej stosuje się także hybrydowe rozwiązania łączące SSVEP z sygnałami EMG lub EOG, umożliwiające bardziej elastyczne sterowanie w złożonych środowiskach interaktywnych.

Jednym z najbardziej znanych interfejsów opartych na SSVEP jest system zaproponowany przez Gao i współpracowników [18], umożliwiający wybór liter na wirtualnej klawiaturze na podstawie częstotliwości migotania poszczególnych pól. Każdy symbol był stymulowany z inną częstotliwością w zakresie 8–15 Hz, a użytkownik, skupiając

wzrok na wybranym polu, generował w korze wzrokowej rytmiczną aktywność o tej samej częstotliwości. Detekcja sygnału realizowana była w czasie rzeczywistym metodą CCA, co pozwalało uzyskać dokładność przekraczającą 95% przy czasie integracji 1–2 s.

W polskim środowisku naukowym warto wyróżnić rozwiązania opracowane przez zespół prof. Andrzeja Materki z Politechniki Łódzkiej [30, 31]. Autorzy zaproponowali system SSVEP wykorzystujący naprzemienną stymulację pól wzrokowych, w której prawa i lewa połowa pola widzenia użytkownika były naprzemiennie pobudzane światłem LED. Takie podejście wzmacniało różnice między sygnałami rejestrowanymi z odpowiednich półkul mózgowych. Dodatkowo zastosowano różnicowy pomiar EEG z elektrod rozmieszczonych symetrycznie nad obszarami potylicznymi (O1, O2), co pozwalało eliminować artefakty symetryczne i poprawiało selektywność pomiaru. Naprzemienna stymulacja pól wzrokowych przyspieszała komunikację między użytkownikiem a systemem, znajdując zastosowanie w praktycznych interfejsach, takich jak wirtualna klawiatura umożliwiająca wybieranie numerów telefonu.

Na Uniwersytecie Warszawskim zespół kierowany przez prof. Piotra Durkę opracował interfejs SSVEP z dynamicznie zmieniającym się zestawem bodźców [14]. System był częścią projektu open-source rozwijanego na Wydziale Fizyki UW. Wykorzystywał on adaptacyjne menu, w którym elementy zmieniały pozycję i kształt w zależności od wyników wcześniejszych klasyfikacji. Takie rozwiązanie zmniejszało zmęczenie użytkownika i skracało czas potrzebny na wybór właściwej opcji. Interfejs testowano w warunkach zbliżonych do rzeczywistych, z użyciem lekkiego, przenośnego zestawu EEG oraz standardowego monitora LCD jako źródła bodźców. Badania wykazały, że nawet przy niższej jakości sygnału możliwe było uzyskanie stabilnych odpowiedzi SSVEP, co potwierdziło użyteczność tego podejścia w środowiskach nielaboratoryjnych.

Różne grupy badawcze eksperymentowały z alternatywnymi formami bodźców. Bakardjian, Tanaka i Cichocki [5] opracowali interfejs z ośmioma komendami, w którym bodźce realizowano za pomocą diod LED rozmieszczonych w okręgu wokół monitora. System osiągał wysoką stabilność i rozdzielczość częstotliwościową przy niewielkim zużyciu energii. Inne prace wykorzystywały wzory szachownicowe lub zmieniające się figury geometryczne jako bodźce wzrokowe, co pozwalało uzyskać wyraźniejsze odpowiedzi SSVEP przy mniejszym zmęczeniu wzroku [10]. Kuś i in. [27] zaproponowali połączenie diod LED i bodźców generowanych na ekranie LCD, co umożliwiło zwiększenie liczby możliwych klas przy zachowaniu synchronizacji czasowej między źródłami światła. Systemy Nakanishiego i współpracowników [36] wprowadziły kodowanie częstotliwościowo-fazowe (FPC), w którym bodźce różniły się nie tylko częstotliwością, lecz także fazą początkową, zwiększając liczbę komend przy ograniczonej przestrzeni ekranu. Bodźce rozmieszczano koncentrycznie wokół punktu fiksacji, co zmniejszało obciążenie wzrokowe i poprawiało komfort użytkowania. Systemy te znalazły zastosowanie m.in. w sterowaniu ruchem kursora, pojazdów mobilnych i dronów. W eksperymentach uzyskiwano czasy reakcji poniżej 2 s przy zachowaniu dokładności powyżej 90%, co czyniło je użytecznymi w sterowaniu w czasie rzeczywistym.

Znaczący rozwój interfejsów SSVEP nastąpił wraz z popularyzacją technologii rzeczywistości wirtualnej (VR) i rozszerzonej (AR). Kosmyna i współpracownicy [26] opracowali system integrujący bodźce SSVEP z wirtualnym środowiskiem, w którym użytkownik mógł wybierać elementy menu jedynie wzrokiem. Bodźce renderowano w przestrzeni 3D,

utrzymując stałą pozycję względem pola widzenia. Kolejne prace, np. autorstwa Cheng i in., wprowadziły mechanizmy kompensacji dryftu spojrzenia oraz dynamicznego dostosowywania parametrów bodźców do indywidualnych cech użytkownika, co umożliwiło stabilną detekcję w warunkach ruchu i zmiennego oświetlenia [11].

3. Projekt oraz implementacja interfejsu SSVEP

W niniejszym rozdziale przedstawiono główne założenia projektowe oraz ogólną koncepcję implementacji systemu interfejsu mózg–komputer opartego na zjawisku wzrokowych potencjałów wywołanych stanu ustalonego. Celem projektu jest opracowanie rozwiązania umożliwiającego sterowanie kursorem myszy za pomocą odpowiedzi neuronalnych generowanych w odpowiedzi na migoczące bodźce wzrokowe. Konstrukcja systemu musi zapewniać nie tylko funkcjonalność, pozwalającą na wykonywanie podstawowych komend ruchu kursora, ale również powtarzalność wyników.

3.1 Założenia projektowe

Zdefiniowano dwie grupy wymagań: funkcjonalne, określające możliwości systemu, oraz pozafunkcjonalne, dotyczące jakości i warunków pracy rozwiązania.

Założenia funkcjonalne systemu

- System umożliwia sterowanie kursorem w czterech kierunkach oraz generowanie kliknięcia lewym przyciskiem myszy.
- Użytkownik wybiera komendę poprzez skupienie wzroku na jednym z pięciu migających bodźców.
- System dokonuje analizy sygnału w oknach czasowych o stałej długości wynoszącej 4 sekundy, z krokiem przesunięcia 100 milisekund.
- Interfejs pozwala na konfigurację parametrów migających pól (położenie, częstotliwość, rozmiar, przezroczystość).

Założenia pozafunkcjonalne systemu

- System oparty jest na architekturze wieloprocessowej w celu uniknięcia blokowania renderowania interfejsu przez zachodzące w tle obliczenia.
- Stabilność działania systemu nie zależy od wahań jakości łącza Bluetooth (zastosowanie buforowania danych).
- Moduł przetwarzania sygnału musi być odporny na zakłócenia sieci energetycznej o częstotliwości 50 Hz.
- Aplikacja działa w sposób deterministyczny, zapewniając synchronizację częstotliwości stymulatora z częstotliwością odświeżania monitora poprzez mechanizm VSync.

- Łączne opóźnienie systemu, od momentu skupienia wzroku do wykonania komendy — nie przekracza 5 sekund, co odpowiada wymaganiom stawianym interfejsom BCI użytkowanym w czasie rzeczywistym [47].


3.2 Model systemu

Ogólna architektura rozwiązania opiera się na interakcji trzech głównych modułów: modułu stymulującego, modułu rejestracji sygnału oraz modułu przetwarzającego. Schemat ogólny modelu systemu, obrazujący przepływ informacji między użytkownikiem a poszczególnymi blokami, przedstawiono na rysunku 3.1.

Moduł stymulujący odpowiada za prezentację bodźców wzrokowych migających pól, które wywołują specyficzną odpowiedź w mózgu użytkownika. Moduł rejestracji jest odpowiedzialny za akwizycję biologicznego sygnału EEG. Zarejestrowane dane trafiają do modułu przetwarzającego, gdzie następuje ich filtracja, analiza i klasyfikacja, której wynik jest przekładany na ruch kursora.

Ze względu na zjawisko globalnej blokady interpretera (GIL) w języku Python, system został zaprojektowany z wykorzystaniem biblioteki *multiprocessing*. Zaimplementowano dwa niezależne procesy: pierwszy odpowiada za moduł stymulujący (renderowanie interfejsu graficznego *overlay*) oraz drugi za moduł rejestracji i przetwarzania sygnału EEG.


Komunikacja między procesami akwizycji i stymulacji odbywa się asynchronicznie za pomocą kolejki komend (*cmd_queue*). Taki podział gwarantuje, że obciążające procesor operacje obliczeniowe nie wpływają na stabilność wyświetlania bodźców na ekranie.



Rysunek 3.1: Model systemu interfejsu SSVEP z podziałem na moduły logiczne.

3.3 Zestaw technologii i proces rejestracji sygnału

Do rejestracji sygnału EEG zdecydowano się zastosować moduł OpenBCI Cyton [50], przedstawiony na rysunku 3.2. Urządzenie to oparte jest na 8-kanalowym wzmacniaczu Texas Instruments ADS1299, 24-bitowym przetworniku analogowo-cyfrowym oraz 8-bitowym mikroprocesorze PIC32MX250F128B firmy Microchip Technology. Komunikacja z jednostką centralną odbywa się bezprzewodowo przy użyciu dedykowanego odbiornika USB.



Rysunek 3.2: Urządzenie OpenBCI Cyton wykorzystane w eksperymencie. Źródło: [50]

Dane poddawane analizie pochodzą z trzech elektrod zlokalizowanych w punktach O1, O2 i Oz (kora wzrokowa) zgodnie z systemem 10–20. Wybór tych miejsc wynika z faktu, że siła odpowiedzi mózgu na migające bodźce jest najsilniejsza w jego potylicznej części.

Głównym elementem implementacji procesu akwizycji jest biblioteka *BrainFlow*, zapewniająca jednolite API do komunikacji z płytką Cyton. W przeciwieństwie do klasycznego podejścia analizującego rozłączne, statyczne bloki danych, w systemie zastosowano mechanizm przesuwne okna czasowego (ang. *sliding window*).

Proces akwizycji przebiega następująco:

1. Nawiązanie połączenia z urządzeniem poprzez port szeregowy i rozpoczęcie strumieniowania danych do wewnętrznego bufora przy częstotliwości próbkowania 250 Hz.
2. Po upływie okresu stabilizacji sygnału, uruchomienie pętli głównej.
3. Co 100 milisekund pobierana jest paczka danych stanowiąca okno o długości 4 sekund (1000 próbek).
4. Nakładające się okna, przesunięte względem siebie zaledwie o 100 milisekund, są przekazywane do modułu przetwarzania.

Zastosowanie okna o długości 4 sekund stanowi optymalny kompromis między stabilnością sygnału dla klasyfikatora a czasem reakcji systemu. Długie okno dostarcza wiarygodnych danych, natomiast bardzo krótki krok przesunięcia (100 ms) umożliwia płynną i błyskawiczną aktualizację wyniku klasyfikacji.

3.4 Implementacja przetwarzania i klasyfikacji sygnału


Surowy sygnał odebrany z elektrod potylicznych (O1, O2 i Oz) poddawany jest wstępnemu oczyszczeniu przed przekazaniem do klasyfikatora. Filtracja realizowana jest z użyciem biblioteki MNE–Python, która implementuje filtry FIR (ang. *Finite Impulse Response*) z oknem Hamminga. Filtry FIR charakteryzują się liniową charakterystyką fazową, co

oznacza, że wszystkie składowe częstotliwościowe sygnału zostają opóźnione o tę samą wartość — w odróżnieniu od filtrów IIR (np. Butterwortha), które wprowadzają nieliniowe zniekształcenia fazowe. Własność ta jest szczególnie istotna dla metody CCA, która opiera się na pomiarze korelacji czasowej między sygnałem EEG a sygnałami referencyjnymi.

Przetwarzanie obejmuje dwa etapy:

1. **Filtr pasmowo-przepustowy** o zakresie 1–40 Hz, eliminujący wolne dryfty sygnału (poniżej 1 Hz) oraz szumy wysokoczęstotliwościowe związane z napięciem mięśniowym (powyżej 40 Hz).
2. **Filtr zaporowy (notch)** o częstotliwości 50 Hz usuwający zakłócenia pochodzące z sieci elektrycznej.

Tak przygotowane przebiegi czasowe trafiają bezpośrednio do algorytmu analizującego. Funkcję realizującą opisaną filtrację pasmowo-przepustową oraz zaporową przedstawiono na listingu 3.1. Wpływ filtracji na sygnał EEG oraz wynikające z niej widmo częstotliwościowe z wyraźnymi prążkami odpowiedzi SSVEP zilustrowano na rysunku 3.3.



Rysunek 3.3: Przykład sygnału SSVEP użytkownika patrzącego na bodziec migający z częstotliwością 10 Hz: EEG w dziedzinie czasu (a); EEG po filtracji w dziedzinie czasu (b); EEG w dziedzinie częstotliwości z widocznymi prążkami na 10 Hz i harmonicznej 20 Hz (c). Źródło: [4].

Dobór częstotliwości bodźców wizualnych jest ograniczony przez częstotliwość odświeżania monitora LCD (60 Hz). Wyświetlacz może generować bodźce jedynie o częstotliwościach będących całkowitymi dzielnikami tej wartości. Spośród dostępnych wartości

wykluczono te, które stanowią wzajemne wielokrotności. Zapobiega to nakładaniu się harmonicznym różnym bodźców w widmie EEG. Na tej podstawie wybrano pięć częstotliwości: 6,66 Hz, 7,5 Hz, 8,57 Hz, 10,0 Hz i 12,0 Hz, odpowiadające kolejno komendom: góra, dół, lewo, prawo i kliknięcie.

Jako docelową metodę klasyfikacji intencji użytkownika zastosowano analizę korelacji kanonicznej (CCA), której podstawy teoretyczne opisano w sekcji 2.5. W procesie detekcji przefiltrowane wielokanałowe sygnały EEG porównywane są ze sztucznie wygenerowanymi sygnałami referencyjnymi dla każdej z pięciu częstotliwości stymulacji. Macierz referencji uwzględnia dwie harmoniczne ($h = 1, 2$), co znacząco zwiększa czułość klasyfikatora. Implementację w języku Python z użyciem biblioteki *scikit-learn* przedstawiono na listingu 3.3.

Samo wyznaczenie częstotliwości o najwyższej korelacji kanonicznej nie jest wystarczające do stabilnego sterowania, ponieważ sygnał EEG jest z natury zaszumiony i pełen artefaktów. W systemie zaimplementowano mechanizm bufora decyzyjnego, który wygładza wynik klasyfikacji w czasie.

Komenda sterująca jest generowana wyłącznie wtedy, gdy ta sama częstotliwość zostanie zaklasyfikowana jako dominująca w $N = 3$ kolejnych, następujących bezpośrednio po sobie oknach czasowych, a obliczony współczynnik korelacji ρ przekroczy ustalony próg $\theta = 0,3$. Jakikolwiek okno niespełniające warunków progowych lub wskazujące inną częstotliwość powoduje pełny reset licznika. Po wysłaniu komendy system wchodzi w blokadę czasową wynoszącą 0,5 sekundy, uniemożliwiającą wielokrotne rejestrowanie tej samej komendy podczas jednego skupienia wzroku. Działanie mechanizmu okna przesuwającego oraz logiki bufora decyzyjnego przedstawiono na listingu 3.2.

Ponieważ okno analizy przesuwane jest co 100 ms ($T_{\text{krok}} = 0,1$ s), łączne minimalne opóźnienie systemu, od momentu skupienia wzroku na bodźcu do wykonania pierwszej komendy wynosi:


$$t_{\min} = T_{\text{okno}} + (N - 1) \cdot T_{\text{krok}} = 4,0 + 2 \cdot 0,1 = 4,2 \text{ s} \quad (3.1)$$

3.5 Interfejs użytkownika i wygląd stymulatora

Moduł stymulujący, odpowiedzialny za prezentację bodźców, został zrealizowany przy użyciu biblioteki *PyQt5* w formie pełnoekranowego okna nakładkowego (ang. *overlay*). W celu wywołania jak najsilniejszej odpowiedzi SSVEP użyto białe kwadraty wyświetlane na czarnym tle. Ich położenie na ekranie odwzorowuje kierunki wywoływanych akcji sterujących kursorem myszy: górny bodziec odpowiada komendzie ruchu w górę, dolny — ruchowi w dół, lewy i prawy — odpowiednim ruchom horyzontalnym, natomiast centralny — kliknięciu lewym przyciskiem myszy.

Aby zapewnić precyzyjną stymulację SSVEP, zjawisko migotania zostało zaimplementowane w oparciu o sprzętowe zliczanie klatek obrazu, co stanowi znacznie stabilniejszą metodę niż użycie tradycyjnych programowych timerów.

Dla każdego bodźca wyliczana jest liczba klatek monitora przypadająca na jeden pełny cykl migotania, zgodnie ze wzorem:



Rysunek 3.4: Wygląd ekranu stymulującego z bodźcami o wysokim kontraście.

$$N_{\text{cykl}} = \frac{f_{\text{monitor}}}{f_{\text{bodziec}}} \quad (3.2)$$

Przykładowo, dla monitora o częstotliwości odświeżania $f_{\text{monitor}} = 60$ Hz i bodźca docelowego $f_{\text{bodziec}} = 7,5$ Hz, pełny cykl trwa dokładnie $N_{\text{cykl}} = 8$ klatek. Generowany w ten sposób sygnał świetlny ma charakter fali prostokątnej o wypełnieniu 50%. Oznacza to, że przez pierwszą połowę cyklu bodziec jest renderowany na ekranie (stan wysoki), a przez drugą połowę pozostaje ukryty (stan niski).

Samo rysowanie bodźców hermetyzowano wewnątrz przeciążonej metody `paintEvent`, dostarczanej przez framework *PyQt5*. Wywoływana jest ona automatycznie przez główny wątek graficzny przy każdym odświeżeniu ekranu z użyciem mechanizmu VSync. W jej wnętrzu inkrementowany jest globalny licznik klatek (`frame_counter`), a stan widoczności stymulatorów określany jest warunkowo przy użyciu operacji modulo. Implementację tego mechanizmu przedstawiono na listingu 3.4.

```

1  def filter_signal(data: np.ndarray, fs: int) ->
    np.ndarray:
2      x = data[np.newaxis, :] # Biblioteka MNE wymaga
        wymiaru (n_channels, n_samples)
3
4      x = filter_data(
5          x, sfreq=fs,
6          l_freq=1.0, h_freq=40.0,
7          method='fir',
8          fir_window='hamming',
9          verbose=False
10     )
11
12     b_n, a_n = iirnotch(50.0, 30.0, fs)
```

```

13     x = lfilter(b_n, a_n, x)
14
15     return x[0]

```

Algorytm 3.1: Funkcja realizująca filtrację pasmowo-przepustową oraz zaporową

```

1  while True:
2      time.sleep(0.1) # Krok przesunięcia okna: 100 ms
3
4      # Pobranie paczki danych z bufora płytki Cyton
5      data = board.get_current_board_data(n_samples)
6      if data.shape[1] < n_samples:
7          continue
8
9      occipital_data = data[eeg_channels][indices, :]
10     detected_f, current_score = classify(occipital_data,
11                                         SAMPLING_RATE, target_freqs)
12
13     # Logika bufora decyzyjnego (Debounce logic)
14     if current_score > THRESHOLD_CCA:
15         if detected_f == last_detected:
16             consecutive += 1
17         else:
18             consecutive = 1
19             last_detected = detected_f
20     else:
21         consecutive = 0
22         last_detected = None
23
24     # Wykonanie komendy po N spójnych odczytach
25     if consecutive >= REQUIRED_STABILITY:
26         if time.time() - last_command_time >=
27             COOLDOWN_SECONDS:
28             command = STIMULI_MAP[last_detected]
29             mouse.execute(command)
30             last_command_time = time.time()
31
32     consecutive = 0
33     last_detected = None

```

Algorytm 3.2: Pętla główna modułu akwizycji realizująca mechanizm okna przesuwnego oraz bufor decyzyjny

```

1  def generate_references(freq, fs, n_samples,
2                          n_harmonics=2):
3      t = np.arange(n_samples) / fs
4      Y = []
5      for h in range(1, n_harmonics + 1):
6          Y.append(np.sin(2 * np.pi * freq * h * t))

```

```

6         Y.append(np.cos(2 * np.pi * freq * h * t))
7     return np.array(Y).T # (n_samples, 2*n_harmonics)
8
9     def compute_cca(eeg_data, fs, target_freqs,
10                    n_harmonics=2):
11         n_samples = eeg_data.shape[1]
12         X = eeg_data.T # (n_samples, n_channels)
13         scores = {}
14         cca = CCA(n_components=1)
15         for freq in target_freqs:
16             Y = generate_references(freq, fs, n_samples,
17                                    n_harmonics)
18             cca.fit(X, Y)
19             X_c, Y_c = cca.transform(X, Y)
20             corr = np.corrcoef(X_c[:, 0], Y_c[:, 0])[0, 1]
21             scores[freq] = max(corr, 0.0)
22     return scores

```

Algorytm 3.3: Funkcje generujące sygnały referencyjne oraz obliczające współczynnik korelacji kanonicznej CCA

```

1     def paintEvent(self, event):
2         self.frame_counter += 1
3         qp = QPainter(self)
4
5         # Wypełnienie tła na czarno w każdej klatce
6         qp.fillRect(self.rect(), Qt.black)
7
8         # Rysowanie aktywnych stymulatorów
9         for stim in self.stimuli:
10             if stim.freq > 0:
11                 # Logika modulacji prostokątnej (Square Wave)
12                 if (self.frame_counter %
13                     stim.frames_per_cycle) <
14                     (stim.frames_per_cycle / 2):
15                     qp.fillRect(stim.rect, stim.color)
16

```

Algorytm 3.4: Fragment metody paintEvent realizujący sprzętowe migotanie bodźców w postaci fali prostokątnej

4. Przeprowadzenie badania i omówienie wyników

Niniejszy rozdział przedstawia metodologię oraz wyniki badania przeprowadzonego z udziałem trzech uczestników. Celem eksperymentu była praktyczna weryfikacja działania systemu w warunkach rzeczywistych, obejmująca ocenę skuteczności klasyfikacji komend, użyteczności interfejsu oraz subiektywnych wrażeń użytkowników. Badanie przeprowadzono zgodnie z protokołem stanowiącym Załącznik A.

4.1 Protokół badania

W badaniu wzięły udział trzy osoby, które nie miały wcześniejszego doświadczenia z interfejsami mózg–komputer. Sesja składała się z sześciu etapów opisanych szczegółowo w protokole (Załącznik A).

Na początku uczestnik zapoznawał się z celem eksperymentu oraz zasadą działania interfejsu SSVEP. Następnie przeprowadzano montaż elektrod EEG w punktach O1, O2 oraz Oz, kontrolując poziom impedancji w celu zapewnienia poprawnej jakości sygnału. Uczestnik zajmował miejsce w odległości około 60–70 cm od monitora. Po przygotowaniu rozpoczynano krótką sesję zapoznawczą, w trakcie której badany mógł swobodnie eksplorować działanie systemu. W dalszej części realizowano zadanie polegające na sterowaniu kursorem i klikaniu w cele o malejących rozmiarach. Czasy ukończenia zadania z klikaniem rejestrowano ręcznie przy użyciu stopera. Następnie przechodzono do zadania oceniającego skuteczność klasyfikacji komend. Uczestnik wykonywał polecenia wydawane przez prowadzącego w losowej kolejności, a każda próba była klasyfikowana pod względem poprawności odpowiedzi systemu.

Po zakończeniu części eksperymentalnej uczestnik wypełniał ankietę dotyczącą subiektywnej oceny działania interfejsu. Obejmuje ona zarówno odczucia związane z jego użytecznością, jak i poziom obciążenia poznawczego oraz fizycznego (Załącznik B).

4.2 Wyniki badania

Pierwsze zadanie polegało na przemieszczeniu kursora myszy i kliknięciu kolejno w trzy czerwone kwadraty o wymiarach 200×200 , 100×100 oraz 50×50 pikseli, wyświetlane na ekranie na raz. Zadanie powtarzano trzykrotnie. Za każdym razem obiekty znajdowały się w tym samym miejscu. Mierzono łączny czas ukończenia każdego podejścia, obejmujący zarówno czas ruchu kursora, jak i czas oczekiwania na reakcję klasyfikatora.

Uczestnik oznaczony jako Osoba 3 nie był w stanie ukończyć zadania w żadnym z podejść z powodu trudności ze skupieniem wzroku na polach stymulatora przy jednoczesnej obecności wszystkich pięciu bodźców na ekranie — szczegółowe omówienie tego przypadku zawiera sekcja 4.4.

Wyniki pozostałych dwóch uczestników zestawiono w tabeli 4.1.

Tabela 4.1: Czasy ukończenia zadania sterowania kursorem [s]

Uczestnik	Podejście 1	Podejście 2	Podejście 3	Średnia	Min / Maks
Osoba 1	261	312	270	281	261 / 312
Osoba 2	207	310	191	236	191 / 310
Osoba 3	zadanie nieukończone				

Osoba 1 uzyskała stabilne wyniki w pierwszym i trzecim podejściu (261 s i 270 s), natomiast drugie podejście było wyraźnie dłuższe (312 s). Osoba 2 osiągnęła najlepszy wynik w trzecim podejściu (191 s), co sugeruje efekt uczenia się — użytkownik stopniowo lepiej opanowywał technikę skupiania wzroku na bodźcu. Znaczące wydłużenie czasu w drugim podejściu u Osoby 2 (310 s) może wynikać z chwilowego zmęczenia lub trudności z trafieniem kursorem w mniejsze kwadraty, co potwierdzają późniejsze odpowiedzi ankietowe tej osoby.

Warto odnotować, że minimalne opóźnienie systemu wynoszące 4,2 s (wynikające z długości okna analizy i bufora decyzyjnego, zgodnie z równaniem 3.1) jest wliczone w każdy zarejestrowany czas. Przy konieczności wykonania kilkunastu komend na jedno podejście, samo opóźnienie systemu stanowi istotną składową łącznego czasu zadania.

Drugie zadanie polegało na wykonaniu przez uczestnika pięciu komend (prawo, lewo, góra, dół, kliknięcie) w trzech podejściach, po jednej komendzie na bodziec. Prowadzący wydawał polecenia ustnie w losowej kolejności. Wynik każdej próby klasyfikowano jako sukces (S), niepowodzenie (N) — brak reakcji systemu w czasie poniżej 8 s — lub błąd (B) — wykonanie innej komendy niż oczekiwana. Odnotowywano również przypadki wielokrotnej aktywacji komendy (SX2, SX3), gdy bufor decyzyjny wyzwał tę samą komendę kilkakrotnie podczas jednego skupienia wzroku.

Zbiorcze wyniki skuteczności przedstawia tabela 4.2, natomiast rozkład wyników per komenda — tabela 4.3.

Tabela 4.2: Zbiorcza skuteczność klasyfikacji komend (15 prób na uczestnika)

Uczestnik	Sukces	Błąd (B)	Niepowodzenie (N)	Wielokrotne
Osoba 1	13/15 (87%)	0/15 (0%)	2/15 (13%)	2/15
Osoba 2	15/15 (100%)	0/15 (0%)	0/15 (0%)	13/15
Osoba 3	9/15 (60%)	5/15 (33%)	1/15 (7%)	4/15

Osoba 1 osiągnęła skuteczność 87%, bez ani jednego błędnego zaklasyfikowania komendy. Jedynym problemem były dwa niepowodzenia przy komendzie góra (częstotliwość 6,66 Hz) — klasyfikator nie przekroczył progu $\theta = 0,3$ w dopuszczalnym czasie. Możliwą przyczyną jest niższa czułość uczestnika na tę konkretną częstotliwość stymulacji.

Tabela 4.3: Skuteczność per komenda — liczba Sukcesów / Błędów / Niepowodzeń w 3 podejściach

Komenda	Osoba 1		Osoba 2		Osoba 3
	S	B/N	S	B/N	S / B / N
Prawo (10,0 Hz)	3/3	0	3/3	0	2/3 / 1B / 0N
Lewo (8,57 Hz)	3/3	0	3/3	0	1/3 / 2B / 0N
Góra (6,66 Hz)	1/3	2N	3/3	0	1/3 / 1B / 1N
Dół (7,5 Hz)	3/3	0	3/3	0	3/3 / 0B / 0N
Klik (12,0 Hz)	3/3	0	3/3	0	2/3 / 1B / 0N

Osoba 2 uzyskała 100% skuteczności klasyfikacji, jednak aż w 13 z 15 prób komenda została aktywowana wielokrotnie zanim użytkownik oderwał wzrok od bodźca. Świadczy to o bardzo silnej odpowiedzi SSVEP u tej osoby przy jednoczesnym zbyt krótkim czasie blokady cooldown (0,5 s) w stosunku do czasu reakcji. Wartość progu $\theta = 0,3$ okazała się zbyt niska dla tego uczestnika — przy silnym sygnale system reagował wielokrotnie w czasie jednego skupienia wzroku.

Osoba 3 osiągnęła skuteczność 60% przy 33% błędów, co jest wynikiem wyraźnie odbiegającym od pozostałych uczestników. Szczegółowe okoliczności tego przypadku omówiono w sekcji 4.4.

4.3 Wyniki ankiety

Po zakończeniu sesji każdy uczestnik wypełnił ankietę oceny systemu złożoną z trzech części: oceny ogólnej (skala 1–5), oceny obciążenia podczas zadania (skala 1–5) oraz pytań otwartych. Wzór ankiety zamieszczono w sekcji B. Wyniki liczbowe zestawiono w tabeli 4.4.

Osoba 1 oceniła system pozytywnie — wysokie noty za intuicyjność i chęć ponownego użycia (5/5), przy umiarkowanej ocenie akceptowalności czasu oczekiwania (3/5). Koncentracja wymagana do obsługi oceniona została bardzo wysoko (5/5), natomiast ogólne zmęczenie było minimalne (1/5), co sugeruje, że sesja nie była nadmiernie obciążająca fizycznie. W odpowiedziach otwartych uczestnik wskazał, że komenda góra sprawiała największą trudność, natomiast kliknięcie działało najszybciej i najbardziej przewidywalnie.

Osoba 2 zgłosiła wyraźny dyskomfort wzrokowy (5/5 zmęczenie wzroku) oraz wysoki poziom frustracji spowodowany wielokrotnymi aktywacjami komend (5/5). Niska ocena braku dyskomfortu bodźców (2/5) i chęci ponownego użycia (2/5) koreluje bezpośrednio z problemem wielokrotnych aktywacji, który był dominującym doświadczeniem tej osoby. Uczestnik zaproponował ciekawe techniki skupiania wzroku — obserwowanie wzorków i cieni wokół kwadratów zamiast patrzenia w ich centrum. Sugerował też możliwość poruszania się i mówienia podczas badania, co jest typową potrzebą użytkowników niezaznajomionych z wymaganiami rejestracji EEG.

Osoba 3 oceniła system bardzo nisko pod względem kontroli nad kursorem (2/5) i zgodności z intencją (2/5), co bezpośrednio wynika z trudności opisanych w sekcji 4.4. Mimo to intuicyjność obsługi i chęć ponownego użycia ocenione zostały stosunkowo

Tabela 4.4: Wyniki ankiety — oceny w skali 1–5

Część	Pytanie / Odczucie	O1	O2	O3
Ocena ogólna	System reagował zgodnie z intencją.	4	3	2
	Czułem/am się w kontroli nad kursorem.	4	4	2
	Czas oczekiwania był akceptowalny.	3	4	3
	Bodźce nie powodowały dyskomfortu.	5	2	1
	Obsługa była intuicyjna.	5	3	4
	Skorzystałbym/am ponownie.	5	2	4
Obciążenie	Wymagana koncentracja.	5	3	5
	Zmęczenie wzroku.	2	5	4
	Frustracja z powodu błędów.	3	5	4
	Ogólne zmęczenie.	1	4	3

wysoko (4/5), co sugeruje, że uczestnik rozumiał ideę systemu i dostrzegał jego potencjał pomimo trudności w sesji. Jako sugestię poprawy wskazał zmniejszenie jasności i kontrastu monitora, co mogło łagodzić dyskomfort wynikający z intensywnego migotania bodźców.

4.4 Dyskusja wyników

Dane z tabeli 4.3 wskazują na wyraźne różnice w skuteczności klasyfikacji w zależności od częstotliwości bodźca. Komenda góra (6,66 Hz) generowała największą liczbę niepowodzeń u Osoby 1, a u Osoby 3 wykazywała zarówno błędy, jak i niepowodzenia. Komenda dół (7,5 Hz) była jedyną, którą Osoba 3 wykonała poprawnie we wszystkich trzech podejściach. Obserwacja ta jest zgodna z wynikami Osoby 3 przy pracy z pojedynczym stymulatorem, gdzie najsilniejsze odpowiedzi rejestrowano właśnie dla 7,5 Hz i 8,57 Hz.

Może to wskazywać na indywidualną wrażliwość kory wzrokowej na poszczególne częstotliwości stymulacji, niezależną od ogólnej jakości odpowiedzi SSVEP [19]. W systemach z większą liczbą użytkowników warta rozważenia byłaby krótka sesja selekcji częstotliwości przed właściwym badaniem.

Uzyskane wyniki skuteczności dla Osoby 1 (87%) i Osoby 2 (100%) mieszczą się w zakresie typowym dla systemów SSVEP opartych na CCA. Systemy opisane przez Gao i współpracowników [18] osiągały dokładność powyżej 95% przy oknie analizy 1–2 s. Zastosowane w niniejszej pracy okno 4 s zwiększa stabilność klasyfikacji kosztem wydłużonego czasu reakcji, co bezpośrednio przekłada się na obserwowane czasy ukończenia zadania pierwszego.

Czasy ukończenia zadania z klikaniem (191–312 s) są wynikiem relatywnie wysokim w porównaniu z tradycyjną myszą, jednak zgodnym z oczekiwaniami dla systemu BCI

z minimalnym opóźnieniem 4,2 s i brakiem sprzężenia zwrotnego wizualnego informującego o stanie klasyfikatora. Wprowadzenie wizualnego wskaźnika wartości ρ w czasie rzeczywistym mogłoby skrócić czas reakcji użytkownika i zmniejszyć liczbę niepowodzeń.

Wyniki Osoby 2 ujawniły pewne ograniczenie obecnej implementacji bufora decyzyjnego. Przy silnej odpowiedzi SSVEP wartość ρ utrzymuje się powyżej progu θ przez cały czas skupienia wzroku na bodźcu, co powoduje cykliczne wyzwalanie komend co 0,5 s (czas blokady cooldown). W 87% prób Osoby 2 komenda była aktywowana więcej niż jeden raz.

Rozwiązaniem tego problemu może być wydłużenie czasu blokady lub wprowadzenie mechanizmu detekcji oderwania wzroku od bodźca, np. na podstawie nagłego spadku wartości ρ poniżej pewnego progu. Alternatywnym podejściem byłoby automatyczne dostosowanie progu θ do charakterystyki sygnału konkretnego użytkownika w sesji kalibracyjnej.

Osoba 3 stanowi przypadek szczególny, wymagający oddzielnego omówienia. Uczestnik wykazywał znaczące trudności ze skupieniem wzroku na wybranym bodźcu w obecności pozostałych czterech stymulatorów na ekranie. Wykluczona została możliwość nieprawidłowego umiejscowienia elektrod oraz zbyt wysokiej impedancji kontaktu. Obniżenie progu klasyfikacji z $\theta = 0,3$ do $\theta = 0,26$ nie przyniosło znaczącej poprawy skuteczności.

Dopiero po usunięciu pozostałych stymulatorów z ekranu i pozostawieniu jednego aktywnego bodźca uczestnik był w stanie wykonać zadanie skuteczności komend, uzyskując zadowalające wyniki dla częstotliwości 7,5 Hz i 8,57 Hz, przy których klasyfikator rejestrował wartości ρ sięgające nawet 0,45. Pozostałe częstotliwości generowały niestabilne lub słabe odpowiedzi.

Zjawisko to jest opisane w literaturze jako *BCI inefficiency* — szacuje się, że około 15–25% populacji nie jest w stanie efektywnie korzystać z interfejsów SSVEP niezależnie od jakości sygnału EEG [42]. Może ono wynikać z indywidualnych różnic neuroanatomicznych w obszarze kory wzrokowej lub z trudności z kontrolą uwagi wzrokowej w obecności wielu konkurujących bodźców. Wynik Osoby 3 wskazuje ponadto na potrzebę adaptacyjnego doboru częstotliwości stymulacji do indywidualnych cech użytkownika — element, który mógłby stanowić kierunek dalszego rozwoju systemu.

Podsumowanie

Celem niniejszej pracy było zaprojektowanie i implementacja interfejsu mózg-komputer umożliwiającego sterowanie kursorem myszy za pomocą wzrokowych potencjałów wywołanych stanu ustalonego (SSVEP). Postawione wymagania obejmowały obsługę pięciu komend sterujących (ruch w czterech kierunkach oraz kliknięcie lewym przyciskiem myszy), działanie w czasie rzeczywistym oraz łączne opóźnienie systemu nieprzekraczające 5 sekund.

W ramach pracy przeprowadzono analizę literatury dotyczącej interfejsów BCI opartych na SSVEP, ze szczególnym uwzględnieniem metod klasyfikacji sygnału EEG. Na tej podstawie zaprojektowano i zaimplementowano system w języku Python, składający się z modułu akwizycji sygnału EEG (płytki OpenBCI Cyton, biblioteka BrainFlow), modułu przetwarzania sygnału (filtracja FIR z oknem Hamminga, filtr zaporowy 50 Hz, biblioteka MNE-Python) oraz modułu klasyfikacji opartego na analizie korelacji kanonicznej (CCA, biblioteka scikit-learn). Moduł stymulujący zrealizowano przy użyciu biblioteki PyQt5 w postaci pełnoekranowej nakładki z pięcioma migającymi bodźcami o częstotliwościach 6,66 Hz, 7,5 Hz, 8,57 Hz, 10,0 Hz i 12,0 Hz, dobranych jako całkowite dzielniki częstotliwości odświeżania monitora (60 Hz). Przeprowadzono również badanie z udziałem trzech uczestników, obejmujące zadanie sterowania kursorem oraz zadanie skuteczności klasyfikacji komend, uzupełnione ankietą subiektywnej oceny systemu.

Zrealizowany system spełnia postawione wymagania funkcjonalne i pozafunkcjonalne. Minimalne opóźnienie od momentu skupienia wzroku do wykonania komendy wynosi 4,2 s, mieszcząc się w założonym limicie 5 s. Badanie z udziałem trzech uczestników wykazało zróżnicowane, lecz obiecujące wyniki. Dwóch uczestników osiągnęło skuteczność klasyfikacji komend na poziomie odpowiednio 87% i 100%, przy czym u drugiego uczestnika zaobserwowano problem wielokrotnych aktywacji tej samej komendy, wynikający z silnej odpowiedzi SSVEP przekraczającej próg klasyfikatora przez cały czas skupienia wzroku. Trzeci uczestnik wykazał znaczące trudności z obsługą systemu przy jednoczesnej obecności pięciu bodźców na ekranie, osiągając skuteczność 60% przy 33% błędnych klasyfikacji. Zjawisko to jest zgodne z opisywanym w literaturze fenomenem *BCI inefficiency*, dotyczącym około 15–25% populacji [42]. Czasy ukończenia zadania sterowania kursorem wyniosły średnio 281 s i 236 s dla dwóch uczestników, którzy zdolali je ukończyć.

Praca potwierdza praktyczną przydatność metody CCA jako klasyfikatora niewymagającego kalibracji per użytkownik w systemach SSVEP działających w czasie rzeczywistym. Wyniki badania wskazują, że nawet przy relatywnie długim oknie analizy (4 s) system jest zdolny do stabilnej klasyfikacji u większości użytkowników. Zidentyfikowano

dwa istotne ograniczenia implementacyjne: brak adaptacyjnego progu klasyfikacji prowadzący do wielokrotnych aktywacji u użytkowników z silną odpowiedzią SSVEP oraz brak mechanizmu selekcji częstotliwości stymulacji dopasowanego do indywidualnych cech użytkownika.

Dalszy rozwój systemu mógłby objąć wprowadzenie krótkiej sesji kalibracyjnej wyznaczającej indywidualny próg θ oraz optymalny czas opóźnienia wykonania kolejnych komend dla każdego użytkownika. Wartościowym uzupełnieniem byłoby również dodanie wizualnego wskaźnika bieżącej wartości współczynnika korelacji kanonicznej ρ w interfejsie graficznym, co pozwoliłoby użytkownikowi na bieżąco oceniać jakość skupienia wzroku i skrócić czas reakcji. Na podstawie sugestii uczestników badania warto rozważyć eksperymenty z bodźcami wyświetlanymi na tle pulpitu systemu operacyjnego zamiast jednolitego czarnego ekranu. Takie podejście mogłoby zmniejszyć dyskomfort wzrokowy przy dłuższym użytkowaniu, choć wiązałoby się z ryzykiem obniżenia amplitudy odpowiedzi SSVEP. Rozszerzenie zestawu elektrod o dodatkowe kanały potyliczne (POz, PO3, PO4) mogłoby zwiększyć czułość klasyfikatora u uczestników z słabą odpowiedzią SSVEP.

Interesującym kierunkiem byłoby także zbadanie możliwości zastąpienia lub uzupełnienia metody CCA algorytmem FBCCA (Filter Bank CCA), który poprzez analizę sygnału w wielu podzakresach częstotliwościowych wykazuje wyższą skuteczność detekcji przy krótszych oknach analizy [10].

Spis literatury

Książki

- [1] Martin Campbell-Kelly i William Aspray. *Computer: A History of the Information Machine*. Westview Press, 2009.
- [2] Walter Isaacson. *Steve Jobs*. Simon i Schuster, 2011.
- [3] J. R. Wolpaw i E. W. Wolpaw. *Brain-Computer Interfaces: Something New Under the Sun*. Oxford University Press, 2012.

Artykuły

- [4] Andrea Apicella i in. „Enhancement of SSVEPs Classification in BCI-Based Wearable Instrumentation Through Machine Learning Techniques”. W: *IEEE Sensors Journal* (2022).
- [5] Hovagim Bakardjian, Toshihisa Tanaka i Andrzej Cichocki. „Optimization of SSVEP brain responses with application to eight-command brain-computer interface”. W: *Neuroscience letters* (2010).
- [6] Jordi Bieger i Gary Garcia-Molina. „Light Stimulation Properties to Influence Brain Activity: A Brain-Computer Interface Application”. W: *Philips Research Technical Note* (2010).
- [7] Guangyu Bin i in. „Online and Offline Analysis of the SSVEP-Based Brain-Computer Interface Using Canonical Correlation Analysis”. W: *IEEE Transactions on Biomedical Engineering*. 2009.
- [8] Andrea Bonci i in. „An Introductory Tutorial on Brain-Computer Interfaces and Their Applications”. W: *Electronics* (2021).
- [9] D. T. Bundy i in. „Contralesional Brain-Computer Interface Control of a Powered Exoskeleton for Motor Recovery in Chronic Stroke Survivors”. W: *Stroke* (2017). URL: <https://pubmed.ncbi.nlm.nih.gov/28550098/>.
- [10] X. Chen i in. „Filter bank canonical correlation analysis for implementing a high-speed SSVEP-based brain-computer interface”. W: *Journal of Neural Engineering* (2015).
- [11] Ming Cheng, Xiaorong Gao i Shang kai Gao. „Design and Implementation of a Real-Time, User-Adaptive SSVEP-Based BCI with Head Movement Compensation”. W: *IEEE Transactions on Neural Systems and Rehabilitation Engineering* (2020).

- [12] K. H. Davis, R. Biddulph i S. Balashek. „Automatic Recognition of Spoken Digits”. W: *Journal of the Acoustical Society of America* (1952).
- [13] Bruce H. Dobkin. „Brain-Computer Interface Technology as a Tool to Augment Plasticity and Repair in Central Nervous System Disorders”. W: *Current Opinion in Neurology* (2007). URL: <https://pubmed.ncbi.nlm.nih.gov/17992096/>.
- [14] Piotr Durka i in. „Open projects for brain-computer interfaces and signal analysis: BCI. fuw. edu. pl and SignalML. org”. W: *Frontiers in Neuroinformatics* (2009).
- [15] Douglas C. Engelbart i William K. English. „A Research Center for Augmenting Human Intellect”. W: *AFIPS Conference Proceedings* (1968).
- [16] O. Friman, I. Volosyak i A. Gräser. „Multiple channel detection of steady-state visual evoked potentials for brain-computer interfaces”. W: *IEEE Transactions on Biomedical Engineering* (2007).
- [17] A. Frolov i in. „Post-stroke rehabilitation training with a motor-imagery-based brain-computer interface (BCI)-controlled hand exoskeleton: a randomized controlled multicenter trial”. W: *Frontiers in Neuroscience* (2017). URL: <https://www.frontiersin.org/articles/10.3389/fnins.2017.00400/full>.
- [18] Xiaorong Gao i in. „Visual and auditory brain-computer interfaces”. W: *IEEE Transactions on Biomedical Engineering* (2014).
- [19] Christoph Guger i in. „How Many People Could Use an SSVEP BCI?” W: *Frontiers in Neuroscience* (2012).
- [20] Haibo He i Dewen Hu. „Brain-Computer Interfaces in Smart Environments: A Review of Recent Advances”. W: *IEEE Access* (2019).
- [21] Leigh R. Hochberg i in. „Reach and grasp by people with tetraplegia using a neurally controlled robotic arm”. W: *Nature* (2012). URL: <https://www.nature.com/articles/nature11076>.
- [22] Herbert H. Jasper. „Report of the committee on methods of clinical examination in electroencephalography”. W: *Electroencephalography and Clinical Neurophysiology* (1958).
- [23] C. Jia i in. „Frequency and Phase Mixed Coding in SSVEP-based Brain-computer Interface”. W: *IEEE Transactions on Biomedical Engineering* (2010).
- [24] E. A. Johnson. „Touch Display — A Novel Input/Output Device for Computers”. W: *Electronics Letters* (1965).
- [25] M Kołodziej. „Przetwarzanie, analiza i klasyfikacja sygnału EEG na użytek interfejsu mózg-komputer”. W: *Praca doktorska, Politechnika Warszawska* (2011).
- [26] Nataliya Kosmyna, Franck Tarpin-Bernard i Bertrand Rivet. „Bringing BCI and HCI Together: Towards Naturalistic Brain-Computer Interface Paradigms for Human-Computer Interaction”. W: *ACM Transactions on Computer-Human Interaction* (2018).
- [27] Rafał Kuś i in. „On the quantification of SSVEP frequency responses in human EEG in realistic BCI conditions”. W: *PloS one* (2013).

- [28] Z. Lin i in. „Canonical correlation analysis for SSVEP-based brain-computer interfaces”. W: *IEEE Transactions on Biomedical Engineering* (2006).
- [29] Scott Makeig i in. „Independent Component Analysis of Electroencephalographic Data”. W: *Advances in Neural Information Processing Systems* (1996).
- [30] A Materka i M Byczuk. „Alternate half-field stimulation technique for SSVEP-based brain–computer interfaces”. W: *Electronics Letters* (2006).
- [31] Andrzej Materka, Marcin Byczuk i Pawel Poryzala. „A virtual keypad based on alternate half-field stimulated visual evoked potentials”. W: *2007 International Symposium on Information Technology Convergence (ISITC 2007)*. 2007.
- [32] Tim R. Mullen i in. „Real-Time Neuroimaging and Cognitive Monitoring Using Wearable Dry EEG”. W: *IEEE Transactions on Biomedical Engineering* (2015).
- [33] S. Müller-Putz i in. „EEG-based neuroprosthesis control: A step towards clinical practice”. W: *Proceedings of the IEEE*. 2008.
- [34] Brad A. Myers. „A Brief History of Human-Computer Interaction Technology”. W: *Interactions*. 1998.
- [35] M. Nakanishi i in. „Enhancing detection of SSVEPs for a high-speed brain speller using task-related component analysis”. W: *IEEE Transactions on Biomedical Engineering* (2018).
- [36] Masaki Nakanishi i in. „A high-speed brain speller using steady-state visual evoked potentials”. W: *International Journal of Neural Systems* (2015).
- [37] Luis F. Nicolas-Alonso i Jaime Gomez-Gil. „Brain Computer Interfaces, a Review”. W: *Sensors* (2012).
- [38] A. M. Norcia i in. „The steady-state visual evoked potential in vision research: A review”. W: *Journal of Vision* (2015).
- [39] A. Poryadina, A. Pavlov i A. Kaplan. „The effect of color and contrast of visual stimuli on the strength of SSVEP responses in a BCI paradigm”. W: *Sensors* (2022).
- [40] D. Regan. „Human brain electrophysiology: Evoked potentials and evoked magnetic fields in science and medicine”. W: *Elsevier* (1989).
- [41] J. Tong i D. Zhu. „Multi-phase cycle coding for SSVEP based brain-computer interfaces”. W: *BioMedical Engineering OnLine* (2015).
- [42] F.-B. Vialatte i in. „Steady-state visually evoked potentials: Focus on essential paradigms and future perspectives”. W: *Progress in Neurobiology* (2010).
- [43] J. J. Vidal. „Toward direct brain-computer communication”. W: *Annual Review of Biophysics and Bioengineering* (1973).
- [44] J. J. Vidal. „Real-Time Detection of Brain Events in EEG”. W: *Proceedings of the IEEE* (1977).
- [45] Y. Wang i in. „Visual fatigue in steady-state visual evoked potential based brain-computer interfaces”. W: *IEEE Transactions on Neural Systems and Rehabilitation Engineering* (2010).

- [46] Yijun Wang, Masaki Nakanishi i Tzyy-Ping Jung. „Visual stimulus design for optimizing SSVEP-based brain-computer interfaces: a review and new perspectives”. W: *Frontiers in Human Neuroscience* (2020).
- [47] J. R. Wolpaw i in. „Brain-computer interfaces for communication and control”. W: *Clinical Neurophysiology* (2002).
- [48] Z. Wu i in. „Stimulator selection in SSVEP-based BCI”. W: *Medical Engineering and Physics* (2008).
- [49] D. Zhu i in. „A Survey of Stimulation Methods Used in SSVEP-Based BCIs”. W: *Computational Intelligence and Neuroscience* (2010).

Źródła internetowe i inne

- [50] OpenBCI. *OpenBCI - Cyton Board Documentation*. Dostęp: 28.11.2025. URL: <https://docs.openbci.com/Cyton/CytonLanding/>.
- [51] Wikipedia. *Fale mózgowie*. Dostęp: 19.10.2025. 2025. URL: https://pl.wikipedia.org/wiki/Fale_m%C3%B3zgowie.

A. Protokół badania

Informacje ogólne

Niniejszy dokument opisuje procedurę sesji badawczej przeprowadzonej w ramach pracy inżynierskiej pt. „Sterowanie kursorem myszy za pomocą potencjałów wywoływanych stanu ustalonego”.

- **Czas trwania sesji:** około 20–30 minut
- **Wymagania sprzętowe:** komputer z monitorem LCD (60 Hz), zestaw EEG OpenBCI Cyton, elektrody żelowe Ag/AgCl
- **Miejsce:** pomieszczenie o kontrolowanym oświetleniu

Przebieg sesji

Krok 1 — Przygotowanie uczestnika (5 minut)

Uczestnik zapoznaje się z celem badania oraz zasadą działania interfejsu SSVEP. Prowadzący informuje, że zadanie polega na skupianiu wzroku na migających kwadratach widocznych na ekranie i że nie wymaga żadnych ruchów ciała.

Krok 2 — Montaż elektrod (5 minut)

Elektrody EEG umieszczane są w punktach O1, O2 i Oz zgodnie z systemem 10-20. Impedancja elektrod sprawdzana jest przed rozpoczęciem pomiaru. Uczestnik siada w odległości około 60–70 cm od monitora.

Krok 3 — Sesja zapoznawcza (3 minuty)

Uruchamiany jest interfejs stymulujący. Uczestnik przez około 3 minuty swobodnie eksploruje działanie systemu, bez rejestrowania wyników. Celem jest oswojenie się z opóźnieniem systemu i sposobem skupiania wzroku.

Krok 4 — Zadanie 1: Klikanie w cele

Na ekranie wyświetlane są kolejno trzy czerwone kwadraty o wymiarach 200×200 , 100×100 oraz 50×50 pikseli. Zadaniem uczestnika jest przemieszczenie kursora i kliknięcie w każdy z nich przy użyciu wyłącznie interfejsu BCI. Zadanie powtarzane jest trzykrotnie. Mierzony jest czas ukończenia każdego podejścia. Prowadzący rejestruje czas przy użyciu stopera.

Krok 5 — Zadanie 2: Skuteczność komend

Prowadzący wydaje ustnie 15 poleceń w kolejności losowej (po 3 powtórzenia każdej z 5 komend: góra, dół, lewo, prawo, kliknięcie). Po każdym poleceniu uczestnik ma 8 sekund

na jego wykonanie. Prowadzący odnotowuje wynik (sukces / niepowodzenie / błędna komenda) na formularzu obserwacyjnym.

Krok 6 — Ankieta (5 minut)

Uczestnik wypełnia ankietę oceny systemu (Załącznik B).

B. Ankieta oceny systemu

Informacje dla uczestnika

Poniższa ankieta dotyczy Twoich wrażeń z korzystania z interfejsu mózg-komputer opartego na SSVEP. Odpowiedzi są anonimowe. Przy każdym pytaniu zaznacz wybraną odpowiedź lub wpisz komentarz.

Identyfikator uczestnika: **Data:**

Część I – Ocena ogólna

Oceń poniższe stwierdzenia w skali od 1 do 5, gdzie: **1** = zdecydowanie nie zgadzam się, **5** = zdecydowanie zgadzam się.

Stwierdzenie	Ocena				
System reagował zgodnie z moją intencją.	1	2	3	4	5
	☐	☐	☐	☐	☐
Czułem/am się w kontroli nad kursorem.	1	2	3	4	5
	☐	☐	☐	☐	☐
Czas oczekiwania na reakcję systemu był akceptowalny.	1	2	3	4	5
	☐	☐	☐	☐	☐
Migające bodźce nie powodowały dyskomfortu wzrokowego.	1	2	3	4	5
	☐	☐	☐	☐	☐
Obsługa systemu była intuicyjna.	1	2	3	4	5
	☐	☐	☐	☐	☐
Chętnie skorzystałbym/skorzystałabym z systemu ponownie.	1	2	3	4	5
	☐	☐	☐	☐	☐

Część II – Obciążenie podczas zadania

Oceń, w jakim stopniu odczuwałeś/aś poniższe odczucia podczas wykonywania zadań (1 = wcale, 5 = bardzo silnie).

Odczucie	Ocena				
Koncentracja wymagana do obsługi systemu.	1	2	3	4	5
	☐	☐	☐	☐	☐
Zmęczenie wzroku po sesji.	1	2	3	4	5
	☐	☐	☐	☐	☐
Frustracja wywołana błędnymi komendami.	1	2	3	4	5
	☐	☐	☐	☐	☐
Ogólne zmęczenie po sesji.	1	2	3	4	5
	☐	☐	☐	☐	☐

Część III – Pytania otwarte

1. Co sprawiało największą trudność podczas korzystania z systemu?

2. Co działało lepiej niż oczekiwałeś/aś?

3. Jakie zmiany poprawiłyby komfort korzystania z systemu?

Dziękuję za udział w badaniu.